



Progetto PMCSN

Gestione automatizzata delle richieste in farmacia tramite sistema Gollmann

Alessio Torroni
0365661

Università degli studi di Roma Tor Vergata

Abstract

Il presente studio analizza un sistema reale di gestione delle richieste farmaceutiche automatizzato, implementato in una farmacia dotata di robot Gollmann. Il sistema è modellato come una rete di code con arrivi non stazionari, due bracci robotici in concorrenza tra prelievi cliente e rifornimenti, e un sottosistema di inventario a revisione periodica con politica (s, S) per cinque classi di farmaco. Obiettivo dello studio è la **riduzione dei costi di esercizio a parità di qualità del servizio**, agendo su due leve operative — la turnazione del personale per fascia oraria e la politica di riordino delle scorte — sotto il vincolo che le perdite per *out-of-stock* restino sotto il 5%. Il confronto tra la gestione attuale e la configurazione ottimizzata, condotto con simulazione a eventi discreti a orizzonte finito e infinito, mostra un risparmio del 22% circa sul costo giornaliero senza violare i vincoli di servizio.

Introduzione

Negli ultimi anni le farmacie hanno iniziato a dotarsi di sistemi automatizzati di dispensazione del farmaco per aumentare efficienza e precisione nel servizio. Il sistema analizzato in questo studio prende come riferimento una farmacia dotata di robot Gollmann, con interfaccia diretta verso le casse e capacità automatica di prelievo e carico.

Nel sistema reale, il personale gestisce due flussi principali di richieste:

- ☐ clienti fisici, serviti da cinque casse collegate al robot,
- ☐ ordini online, gestiti da una cassa separata.

Le richieste, una volta inserite, vengono inoltrate a un dispatcher, che le smista ai due bracci robotici Gollmann. Per evitare perdite legate alla mancata disponibilità di farmaci, è integrato un sistema di inventario per classi di farmaco, con carico autom-

atizzato attivato da alert e gestito da due magazzinieri. I clienti fisici, ritirati i farmaci, saldano l'ordine presso le casse di pagamento in uscita.

Il *miglioramento atteso* non è un'evoluzione dell'architettura, bensì la **riduzione dei costi operativi** del sistema esistente, perseguita con la scelta ottima dei parametri gestionali e verificata quantitativamente nel confronto finale.

Termini Chiave

Di seguito i termini chiave dello studio.

Cliente fisico

Utente che si presenta fisicamente in farmacia e viene servito da uno dei farmacisti al banco.
--

Cliente Online

Utente che effettua un ordine tramite e-commerce, gestito da un operatore dedicat.
--

Dispatcher
Sistema automatico che riceve gli ordini completati da tutte le casse e li instrada verso i due bracci robotici Gollmann.
Robot Gollmann
Sistema robotico automatizzato che preleva i farmaci dagli scaffali interni al banco dei farmaci.
Braccio Due
Braccio robotico dotato di una singola coda, alimentata dal dispatcher, dedicato esclusivamente alle richieste dei clienti (nessun rifornimento).
Braccio Uno
Braccio robotico dotato di due code distinte: una per le richieste dei clienti provenienti dal dispatcher e una per il carico merci proveniente dal magazzino.

Inventory system
Sistema che tiene traccia del livello di scorte per classi di farmaci e genera alert periodici automatici in caso di superamento della soglia minima.
Magazziniere
Figura che interviene in risposta agli alert generati dall'inventory system ad ogni revisione periodica delle scorte, caricando i prodotti nel modulo di carico del robot.
Cassa Pagamento
Postazione in uscita (due sportelli) presso cui i clienti fisici saldano l'ordine dopo il prelievo robotizzato. I clienti online, che hanno già pagato, non vi transitano.

1 Scopi e Obiettivi

Trattandosi di un sistema *già esistente e operativo*, lo studio non mira a modificarne l'architettura, bensì a **valutarne le prestazioni** e a **ottimizzarne la gestione operativa a costo minimo**. L'obiettivo primario è la **riduzione dei costi di esercizio a parità di qualità del servizio**: si vuole individuare il modo più economico di far funzionare la farmacia senza degradare l'esperienza del cliente e senza mettere a rischio la stabilità del cuore automatizzato del sistema, i due bracci robotici.

I costi in gioco e i rischi da governare

Ogni *out-of-stock* (OOS) — un farmaco richiesto ma non disponibile a banco al momento del prelievo — è una **vendita persa**, dunque una perdita economica diretta (il cliente rinuncia all'articolo e la farmacia perde il relativo margine). Contenere gli OOS richiede scorte adeguate, ma tenerle richiede a sua volta rifornimenti frequenti, che caricano i bracci robotici.

Ed è proprio il carico sui bracci il punto delicato. Una domanda eccessiva ai bracci — generata sia dai prelievi cliente sia dai rifornimenti — espone a **tre problemi distinti**:

- **out-of-stock**: se il braccio non riesce a ricaricare le scorte al ritmo con cui vengono

consumate, il banco si svuota e crescono le vendite perse;

- **perdita della stazionarietà**: se il tasso di arrivo al braccio supera il suo tasso di servizio ($\lambda > \mu$), la coda cresce illimitatamente e il sistema non raggiunge uno stato stazionario — una condizione di collasso operativo, non solo di lentezza;
- **aumento eccessivo dei tempi di risposta**: anche restando stabile ($\lambda < \mu$), avvicinandosi alla saturazione i tempi di attesa esplodono (andamento $\rho/(1 - \rho)$), degradando la qualità del servizio e traducendosi anch'essi in una perdita (clienti insoddisfatti, minore capacità di smaltire la giornata).

Poiché i bracci sono **una risorsa fisica non aumentabile** (due braccia, capacità fissa), non si può risolvere il problema aggiungendo serventi: occorre *governare il flusso* che li raggiunge.

Le due leve operative

Lo studio agisce quindi su due leve che non alterano il sistema fisico:

- la **politica di riordino** (s, S) delle scorte a banco, per classe di farmaco, che regola *quanto* e *quando* rifornire (e quindi il livello di OOS e il carico di rifornimento sui bracci);

- la **turnazione del personale** (farmacisti alle casse e magazzinieri) per fascia oraria, in funzione della domanda istantanea.

Il ruolo delle casse merita una precisazione, perché non è ovvio. Le casse sono il punto d'ingresso obbligato dei clienti e fungono da **regolatore (contingentamento) del flusso** verso i bracci: con *meno casse attive* i job raggiungono i bracci a frequenza più bassa (le casse li trattengono più a lungo a monte), riducendo il carico di picco a valle e allontanando i tre rischi appena descritti; per contro, *meno casse* significa più attesa in coda alle casse, quindi un **tempo di risposta più alto**. Ridurre il personale, inoltre, abbatta il costo dominante di esercizio. La turnazione delle casse è dunque una leva a doppio taglio, che agisce contemporaneamente sul costo, sulla regolarità del flusso ai bracci e sul tempo d'attesa del cliente.

L'obiettivo come trade-off

L'obiettivo dello studio è trovare il **miglior compromesso** tra tutte queste tensioni: minimizzare il costo totale giornaliero

$$C_{tot} = C_{personale} + C_{giacenza} + C_{shortage} + C_{ordini},$$

mantenendo gli out-of-stock sotto una soglia accettabile, garantendo la stazionarietà di tutti i centri e non lasciando degenerare il tempo di risposta.

Obiettivi dello studio (vincoli di servizio)

Le perdite per mancanza di scorte (<i>out of stock</i>) devono essere mantenute sotto la soglia	5%
Tutti i centri, i bracci robotici in primis, devono restare stabili ($\rho < 1$): il tasso di arrivo non deve superare il tasso di servizio	$\rho < 1$
Il tempo di risposta end-to-end del cliente non deve peggiorare in modo significativo rispetto alla gestione attuale (guardrail, ancorato ai valori osservati sulla configurazione di partenza)	—

QoS: Quality of Service

Ridurre i costi di esercizio senza peggiorare in modo significativo le prestazioni percepite dal cliente (tempo di risposta), senza superare il vincolo sull'out-of-stock e senza compromettere la stabilità dei centri.

2 Modello concettuale

Il sistema di gestione delle richieste farmaceutiche può essere modellato come una rete di code, costituita da diversi centri operativi: casse, dispatch-

Ogni leva sposta l'equilibrio: soglie di riordino più alte riducono gli OOS ma aumentano giacenza e carico di rifornimento; meno casse tagliano i costi e regolarizzano il flusso ai bracci ma allungano l'attesa. Il punto ottimo è la combinazione di (s, S) e staffing che minimizza il costo complessivo rispettando i vincoli di servizio.

Va infine chiarita una scelta di scope: il **focus è il sottosistema di dispensazione e rifornimento** (bracci e inventario). Per questo — come discusso nel modello concettuale — gli abbandoni dei clienti in coda alle casse sono esclusi: in questo modo l'intera domanda generata raggiunge i bracci e l'inventario, che ricevono così un processo di arrivi *conservato e ben definito*, condizione ideale per isolarne il comportamento. Come conseguenza, la qualità del servizio non si misura più sugli abbandoni ma sul **tasso di out-of-stock** (vincolo quantitativo) e sul **tempo di risposta** end-to-end del cliente (guardrail).

Accanto all'obiettivo primario, lo studio persegue obiettivi di *caratterizzazione* (stimare tempo di risposta end-to-end, attese e utilizzazioni per centro, throughput, livello medio delle scorte e perdite per out-of-stock, con intervalli di confidenza) e obiettivi *metodologici*: analisi del transitorio e stima del warm-up, simulazione a orizzonte finito e infinito, verifica e validazione del modello.

er, bracci robotici Gollmann, casse di pagamento e magazziniere, più un sistema di inventario che ne governa le scorte. I clienti sono suddivisi in due categorie:

- Clienti fisici, che si presentano direttamente in farmacia;
- Clienti online, che effettuano ordini tramite piattaforma e-commerce.

Per poter ricevere i farmaci, un cliente — indipendentemente dal canale di provenienza — deve prima essere preso in carico da una cassa.

Nel dettaglio, i clienti fisici affluiscono in una coda unica, in cui vengono serviti da cinque farmacisti secondo politica FIFO (first-in, first-out). I clienti online affluiscono invece in una seconda coda separata, gestita da una sesta cassa dedicata.

Un ordine può contenere **più farmaci, anche di classi diverse**: il numero K di farmaci richiesti e la classe di ciascun farmaco sono attributi dell'ordine, estratti al suo ingresso nel sistema. Al completamento del servizio al banco (fisico oppure online), l'ordine viene inviato al dispatcher, che rappresenta il nodo di smistamento del sistema.

Un ordine = un job (scelta di modellazione)

Una scelta strutturale di questo studio è che l'ordine attraversi la rete come **un unico job**: la richiesta di K farmaci non genera K job distinti, ma entra nel *tempo di servizio* del braccio robotico, che deve eseguire K prelievi consecutivi. Una prima versione del modello spaccettava invece ogni ordine in K frammenti (un job per farmaco), con chiusura dell'ordine al completamento di tutti i frammenti (struttura fork-join): questa scelta costringeva la cassa d'origine a restare impegnata fino al termine del prelievo robotizzato, gonfiandone artificialmente l'utilizzazione, e portava la rete fuori dalle classi di modelli trattabili. Con la convenzione “un ordine = un job” ogni centro si libera al proprio completamento, le utilizzazioni riflettono il lavoro effettivo di ciascun centro e il numero di job si conserva lungo il percorso — proprietà che sarà sfruttata sia nell'analisi del flusso forzato sia nei bilanci di verifica.

Il dispatcher è modellato come una coda a servente singolo, con scheduling FIFO. Una volta completato il breve servizio di smistamento, l'intero ordine è instradato verso uno dei due bracci robotici:

- **Braccio Uno**, dotato di due code proprie, nelle quali confluiscono sia le richieste dei clienti sia i rifornimenti provenienti dal magazzino;
- **Braccio Due**, dotato di una singola coda, nella quale confluiscono esclusivamente le richieste dei clienti.

Instradamento probabilistico e finestra protetta

La logica di smistamento del dispatcher è uno *scheduling probabilistico a probabilità fisse*: un ordine cliente è inviato al Braccio Uno con probabilità $p_{b1} = 0,20$ e al Braccio Due con probabilità $p_{b2} = 0,80$. Nei **primi 10 minuti di ogni ciclo di revisione delle scorte** (ciclo da 30 minuti) il dispatcher instrada inoltre il 100% dei clienti al Braccio Due (*finestra protetta*), lasciando il Braccio Uno dedicato ai soli rifornimenti appena generati dalla revisione.

Anche questa è una scelta di simulazione da motivare. Il codice implementa in alternativa una politica *overflow* (l'ordine va al Braccio Uno solo se lo trova completamente scarico), che è autoregolante ma **stato-dipendente**: con essa non esistono probabilità di instradamento note a priori, quindi non è possibile calcolare i tassi di ingresso ai bracci ($\lambda_{\text{centro}} = X_{\text{prec}} \cdot p$) né condurre l'analisi del flusso forzato e la validazione per centro. Si è quindi adottato il routing probabilistico fisso, le cui probabilità sono *variabili di progetto note*: la quota verso Braccio Uno è bassa perché quel braccio è già impegnato dai rifornimenti, e il valore $p_{b1} = 0,20$ è stato scelto, dopo un confronto simulativo tra split fissi, come compromesso tra stabilità del Braccio Uno e tempo di risposta di sistema. La finestra protetta è un routing *tempo-variante deterministico* (schedulato): mantiene noto il tasso d'ingresso a ciascun braccio per intervallo, analogamente alla gestione delle fasce orarie.

Il **Braccio Uno** si distingue per la doppia funzionalità: oltre a servire le richieste dei clienti, gestisce il carico delle scorte provenienti dal magazzino. Per questo dispone di due code distinte:

- una per le richieste cliente, alimentata dal dispatcher;
- una per le richieste di carico, alimentata dal magazzino.

La disciplina tra le due code è a **priorità non-preemptive**: un servizio in corso non viene mai interrotto e, al completamento, si sceglie la coda da servire. La precedenza è assegnata ai **prelievi cliente**: un carico di rifornimento (che muove molte confezioni ed è quindi lungo) attende che non vi siano clienti in coda. La motivazione è duplice: (i) i pochi ordini cliente instradati al Braccio Uno non devono accodarsi dietro carichi lunghi,

così i loro tempi di risposta restano allineati a quelli del Braccio Due; (ii) il rifornimento tollera l'attesa per costruzione, perché le scorte a banco — dimensionate dalla politica (s, S) — fungono da buffer di disaccoppiamento tra domanda e carico.

Al completamento del prelievo, i clienti **fisici** proseguono verso la **Cassa Pagamento** (coda unica, due sportelli) per il saldo, e quindi escono dal sistema; i clienti **online**, che hanno già pagato al momento dell'ordine, escono direttamente dal braccio.

Inventario, rifornimenti e out-of-stock

Per monitorare la disponibilità dei prodotti nel robot è presente un inventory system per classi di farmaco, ognuna gestita secondo un modello (s, S) a revisione periodica. Le classi considerate sono cinque: *Farmaci con ricetta*, *Farmaci da banco (SOP/OTC)*, *Integratori*, *Dispositivi medici* e *Preparazioni galeniche*.

Ogni 30 minuti l'inventory system rivede i livelli: se la disponibilità di una classe è scesa sotto la soglia minima s , genera un ordine di rifornimento che riporta la scorta al livello massimo S (politica *order-up-to*); per ciascuna classe può essere pendente **un solo ordine** alla volta. L'ordine è preso in carico dal magazziniere che, prelevato e spaccettato il collo dal magazzino interno, lo immette nella coda di carico del Braccio Uno. Il carico a banco è **incrementale**: le Q confezioni di un rifornimento diventano disponibili una alla volta durante il servizio di carico, non in blocco alla sua conclusione — come avviene fisicamente — così un prelievo concorrente può già attingere alle unità caricate.

Nonostante l'inventory system, si considerano eventi di perdita per **out-of-stock**: se al momento del prelievo un farmaco dell'ordine non è disponibile a banco, quel singolo articolo è perso (il cliente rinuncia all'articolo, l'ordine prosegue con gli altri). La politica è quindi *lost-sales*: la domanda insoddisfatta non è arretrata (nessun backorder) — in farmacia il cliente non attende il riordino, acquista altrove. La metrica di servizio dell'inven-

tario è la probabilità di out-of-stock per articolo, $P(\text{OOS}) = \text{articoli persi} / \text{articoli domandati}$.

Abbandoni: fuori scope (scelta motivata)

Nel sistema reale un cliente fisico può abbandonare la coda delle casse se l'attesa supera la sua pazienza (*reneging*). Il fenomeno è stato modellato (con una mistura di pazienze) ma è **disattivato** in tutti gli esperimenti di questo studio, per due ragioni. Primo, il focus dello studio è l'inventario: senza abbandoni tutta la domanda generata raggiunge i bracci, e la domanda vista dall'inventario coincide con il processo d'arrivo esterno, ben definito e indipendente dalla congestione delle casse — la condizione ideale per dimensionare la politica (s, S) . Secondo, la contabilità degli articoli si semplifica (generati = domandati), rendendo esatti i bilanci usati in verifica. La conseguenza sul disegno dello studio è che il vincolo di servizio sulle casse non è più il tasso di abbandono ma il **tempo di risposta**: senza *reneging* una configurazione di casse troppo povera non perde clienti ma ne fa crescere l'attesa, ed è su quella grandezza che va sorvegliato il taglio del personale.

Stato del Sistema

Le seguenti variabili rappresentano ad alto livello lo stato del sistema:

Stato di ciascuna coda
empty (vuota)
not empty (non vuota)

Stato di ciascun servente dei centri con una singola coda
idle (libero)
busy (occupato)

Stato del servente del centro con due code (Braccio Uno)
idle (libero)
busy_p (occupato da un prelievo cliente)
busy_c (occupato da un carico di rifornimento)

Inventario (per ciascuna delle 5 classi)
livello di scorta corrente $l_c(t) \geq 0$
ordine pendente (assente / quantità residua)

Al livello delle specifiche, lo stato del sistema è riassunto dal vettore

$$x(t) = (n_C, n_O, n_D, (n_{B1}^p, n_{B1}^c), n_{B2}, n_P, n_M, \mathbf{L}(t), \mathbf{O}(t), \varphi(t))$$

dove n_X è il numero di job nel centro X (in coda più in servizio):

- n_C Farmacisti (5 serventi eterogenei), n_O Cassa Online, n_D Dispatcher, n_{B2} Braccio Due, n_P Cassa Pagamento (2 serventi) e n_M Magazziniere (2 serventi), con $n_X \in \mathbb{N}$;
- il Braccio Uno serve due classi a priorità non-preemptive, quindi ha due componenti: n_{B1}^p (prelievi cliente) e n_{B1}^c (richieste di carico);
- $\mathbf{L}(t) = (l_1, \dots, l_5)$, con $l_c \in \{0, \dots, S_c\}$ livello di scorta della classe c ; la politica è *lost-sales*, quindi $l_c \geq 0$;
- $\mathbf{O}(t) = (o_1, \dots, o_5)$, con o_c quantità di riordino ancora pendente della classe c ($o_c = 0$ se nessun ordine è in volo: un solo ordine pendente per classe);
- $\varphi(t) = \lfloor t/1800 \rfloor \bmod 24 \in \{0, \dots, 23\}$ è la fascia oraria corrente, rilevante nell'orizzonte finito per via degli arrivi non stazionari (NSPP).

Lo stato di ciascuna coda (*empty/not empty*) e di ciascun servente (*idle/busy*) si deriva dalla popolazione del centro: il numero di serventi occupati è $\min(n_X, m_X)$, con il vincolo di consistenza per cui un servente è *idle* solo se la sua coda è vuota. Una precisazione è dovuta per le casse: poiché i cinque farmacisti hanno velocità diverse, per una descrizione esatta occorre sapere *quali* serventi sono occupati, non solo quanti; a livello computazionale lo stato è infatti mantenuto per singolo servente, mentre per le leggi operazionali (Little, utilizzazioni) è sufficiente la popolazione n_X . Lo stato cambia soltanto in corrispondenza di un evento; gli eventi artificiali (campionamento, cambio fascia, revisione delle scorte senza ordine) non alterano lo stato fisico del sistema.

Quanto descritto finora nel modello concettuale si può schematizzare nell'immagine che segue. L'immagine mostra una specifica del precedente schema descrittivo ad alto livello.

Eventi

Gli eventi considerati in tutti i centri del sistema sono:

- ☐ Completamento del servizio di un job
- ☐ Cambio di fascia oraria

Altri eventi che possiamo considerare nel centro “Casse” sono:

- ☐ Arrivo di un nuovo job nella coda alle casse

Altri eventi che possiamo considerare nel centro “Braccio Uno” sono:

- ☐ Arrivo di un nuovo ordine cliente nella coda dei prelievi
- ☐ Arrivo di un nuovo ordine di carico nella coda dei rifornimenti
- ☐ Ingresso a banco di una singola confezione durante un carico (carico incrementale)
- ☐ Perdita di un articolo per assenza del farmaco (out-of-stock)

Altri eventi che possiamo considerare nel centro “Braccio Due” sono:

- ☐ Arrivo di un nuovo ordine cliente nella coda dei prelievi
- ☐ Perdita di un articolo per assenza del farmaco (out-of-stock)

Altri eventi che possiamo considerare nel sistema “Banco dei Farmaci” (Inventory System) sono:

- ☐ Decremento della giacenza di una classe a seguito di un prelievo riuscito
- ☐ Revisione periodica delle scorte con eventuale generazione dell'ordine di riordino (al superamento della soglia minima s)
- ☐ Ricezione di una consegna dal magazziniere con conseguente incremento della giacenza (una confezione alla volta)

Inoltre, nei centri “Dispatcher”, “Cassa Online”, “Cassa Pagamento” e “Magazziniere”

possiamo considerare come evento l'arrivo di un nuovo job.

Descrizione degli Eventi

Di seguito si descrivono brevemente gli eventi che governano la dinamica della simulazione (modellata come simulazione ad eventi discreti):

- ☐ **ARRIVAL**: arrivo di un job presso un centro. Per i centri d'ingresso (Casse, Cassa Online) deriva dal processo di Poisson non omogeneo esterno; per i centri interni deriva dall'instradamento del dispatcher, dei bracci o del magazziniere.
- ☐ **DEPARTURE**: completamento del servizio di un job presso un centro e suo eventuale instradamento al centro successivo secondo la matrice di routing.
- ☐ **TIMECHANGE**: cambio di fascia oraria (ogni 30 minuti) con conseguente aggiornamento dell'intensità di arrivo $\lambda(t)$.
- ☐ **SLOTCHANGE**: revisione periodica delle scorte da parte dell'inventary system ed eventuale generazione degli ordini di rifornimento. È un *evento artificiale*: se nessuna classe è sotto soglia non altera lo stato fisico.
- ☐ **RESTOCK**: ingresso a banco di una singola confezione durante il servizio di carico del Braccio Uno (carico incrementale); aggiorna il livello di scorta della classe.
- ☐ **COMPLETION**: chiusura dell'ordine cliente verso la cassa d'origine al termine del percorso.
- ☐ **ABANDON**: abbandono di un cliente dalla coda delle casse allo scadere della sua pazienza. Il tipo di evento esiste nel modello ma, per la scelta di scope discussa sopra, **non viene mai schedato** negli esperimenti di questo studio.
- ☐ **SAMPLING**: evento tecnico di campionamento usato per il calcolo delle statistiche di finestra (artificiale, non altera lo stato).

Analisi spese e profitti

L'analisi economica del sistema mette in relazione i *costi* di esercizio con le *perdite* dovute al mancato servizio, allo scopo di confrontare le configurazioni operative su un'unica scala monetaria (€/giorno).

Componenti di costo

- **Costo del personale**: costo orario medio lordo aziendale di **26 €/h per farma-**

cista (cassa) e **18 €/h per magazziniere**, moltiplicato per le ore-persona effettivamente schedate nella giornata. È la voce dominante (con 5 casse e 2 magazzinieri sempre attivi: $12 \cdot (5 \cdot 26 + 2 \cdot 18) = 1992$ €/giorno) ed è la leva principale di risparmio.

- **Costo di giacenza (holding):** proporzionale al livello medio di scorta a banco, $C_{\text{giac}} = \sum_c h_c \cdot \bar{l}_c$, con h_c derivato dal valore unitario della classe (tasso di immobilizzo $\approx 25\%$ /anno): $h = \{0,0151, 0,0041, 0,0068, 0,0103, 0,0137\}$ €/unità/giorno per le classi 1–5.
- **Costo di penuria (shortage / lost-sales):** ogni articolo perso per out-of-stock è una vendita persa, valorizzata con il margine unitario della classe: $p = \{8,8, 2,4, 4,0, 6,0, 8,0\}$ €/unità.
- **Costo amministrativo d'ordine:** $c = 2,5$ € per ordine di rifornimento emesso.

Per evitare doppi conteggi, la manodopera del magazziniere è contata *una sola volta*, nel costo del personale (turni): il costo d'inventario comprende solo giacenza, shortage e ordini.

Asimmetria dei costi d'inventario

Il rapporto tra costo di shortage e costo di giacenza è dell'ordine di $p_c/h_c \approx 500$: tenere a scaffale un'unità per un giorno costa centinaia

di volte meno che perderne la vendita. Ne discende una lettura importante per l'ottimizzazione: **l'inventario non è una leva di costo ma un guardrail** — non conviene mai barattare out-of-stock per risparmiare giacenza, e le soglie s vanno dimensionate per coprire la domanda durante il tempo di rifornimento, non minimizzate. Il risparmio economico va cercato invece sul personale.

Funzione obiettivo

La configurazione ottima è definita come quella che **minimizza il costo totale giornaliero sotto i vincoli di servizio**:

$$\begin{aligned} &\min C_{\text{tot}} \\ \text{s.t. } &P(\text{OOS}) \leq 5\%, \quad \mathbb{E}[T_{\text{sist}}] \text{ non degradato,} \end{aligned}$$

dove il costo di shortage già presente in C_{tot} penalizza economicamente l'out-of-stock e il vincolo del 5% ne fissa il tetto. Si è *deliberatamente evitato* uno “score” pesato prestazioni/costo con pesi arbitrari: ogni dimensione del trade-off è portata in euro (il tempo del cliente, dove serve per confrontare staffing alternativi, è monetizzato con un valore del tempo esplicito e dichiarato, cfr. sezione sulla ricerca dello staffing) oppure trattata come vincolo. Le scelte finali sono operate su **fronti di Pareto** costo-servizio, così che il compromesso resti visibile e discutibile invece che nascosto in un peso.

3 Modello delle specifiche

Casse ($M/M/m$ a serveri eterogenei)

- Arrivi Markoviani nella coda alle casse fisiche: $\lambda_C(t) = 0,95 \lambda(t)$ (NSPP)
- Coda unica FIFO, $m = 5$ serveri a velocità diverse
- Tempi di servizio esponenziali con medie eterogenee, **misurate presso la farmacia reale**:
 - Cassa 1: $\mathbb{E}[S_1] \approx 121,5$ s
 - Cassa 2: $\mathbb{E}[S_2] \approx 148,6$ s
 - Cassa 3: $\mathbb{E}[S_3] \approx 135,0$ s
 - Cassa 4: $\mathbb{E}[S_4] \approx 162,1$ s
 - Cassa 5: $\mathbb{E}[S_5] \approx 108,0$ s
- Media aritmetica dei tempi: $\overline{\mathbb{E}[S]} = 135$ s

images/immagine_casse.png

Le casse fisiche sono modellate come un centro multi-server a coda unica con cinque serveri a velocità diversa (serveri eterogenei): il servizio comprende l'accoglienza, la ricezione della ricetta o della richiesta, l'inserimento dell'ordine a sistema e le indicazioni al cliente, con durate medie diverse da farmacista a farmacista (esperienza, mansioni accessorie). Ciascun servere ha tempo di servizio esponenziale con media propria: il sistema non è quindi un $M/M/m$ omogeneo e la dizione $M/M/m$ va intesa nel senso di multi-server markoviano con tassi di servizio distinti. La scelta della distribuzione esponenziale — che ha moda in zero, poco realistica per un servizio con durata minima fisiologica — è discussa e difesa quantitativamente nella sezione di validazione, dove un test di sensitività mostra che la forma della distribuzione alle casse non altera le conclusioni dello studio.

La farmacia osservata è operativa nella fascia oraria compresa tra le 08:00 e le 20:00 (12 ore, 43 200 s); il flusso di arrivi è stato suddiviso in 24 intervalli temporali di 30 minuti, come rappresentato nel grafico seguente.

Osservando l'andamento dei dati emergono picchi significativi nelle fasce di tarda mattinata (11:30–12:30) e di sera (17:30–19:30), intervallati da periodi di minore affluenza (prime ore del mattino, primo pomeriggio). Questa variabilità temporale — con variazioni anche superiori al 100% tra fasce contigue — rende inadeguato un modello stazionario: il processo di arrivo è quindi modellato come **processo di Poisson non omogeneo** (NSPP), con intensità $\lambda(t)$ costante a tratti sulle 24 fasce. La media giornaliera del profilo è $\bar{\lambda} = 0,018664$ req/s, pari a circa 806 clienti al

giorno.

I tre slot di punta sono stati **limitati (cap)** a $\lambda = 0,0255$ req/s (il picco osservato raggiungeva 0,0304). La motivazione è di stabilità ed è resa quantitativa nell'analisi del flusso forzato: a λ oltre $\approx 0,0255$ l'utilizzazione del braccio robotico più carico supererebbe 0,95, portando il sistema in prossimità della saturazione entro la fascia; il cap rappresenta di fatto la capacità di accettazione della farmacia nelle ore di punta. I clienti vengono gestiti al banco secondo una disciplina FCFS.

Cassa Online ($M/M/1$)

- ❑ Arrivi Markoviani di ordini online:
 $\lambda_{\text{online}}(t) = 0,05 \lambda(t)$
- ❑ Non è presente coda fisica di clienti, ma un flusso di richieste generate dal sito
- ❑ Tempi di servizio esponenziali con media $\mathbb{E}[S] = 60$ s

La cassa online è modellata come un sistema $M/M/1$: un singolo servente che processa sequenzialmente gli ordini effettuati tramite il sito web della farmacia. Non rappresenta un punto di accesso fisico, ma un canale alternativo attraverso cui una parte degli utenti inoltra le proprie richieste da remoto.

Dall'osservazione dei dati, circa il **5% degli arrivi giornalieri** proviene dal canale online: a fronte di una media di ≈ 806 arrivi totali al giorno, la cassa online gestisce circa 40 ordini/giorno. La frazione è modellata con lo stesso processo di Poisson non omogeneo:

$$\lambda_{\text{online}}(t) = 0,05 \lambda(t),$$

Dispatcher ($M/M/1$)

- ❑ Arrivi determinati dall'uscita dalle casse fisiche e dalla cassa online
- ❑ Tempo di servizio esponenziale: $\mathbb{E}[S] = 3$ s
- ❑ Funzione: instradare *l'intero ordine* verso uno dei due bracci
- ❑ Smistamento probabilistico fisso ($p_{b1} = 0,20$, $p_{b2} = 0,80$) con finestra protetta di carico (primi 10 min di ogni ciclo da 30)

Il dispatcher rappresenta un'unità logica software del sistema: riceve in ingresso gli ordini già completati dalle casse fisiche e dalla cassa online, senza distinzione tra i due canali, e li instrada ai bracci.



ottenuto per assottigliamento (thinning) probabilistico del flusso esterno, che preserva la proprietà di Poisson.

Il tempo di servizio è modellato come esponenziale con media $\mathbb{E}[S] = 60$ s: riflette la natura del processo di evasione degli ordini online (verifica, conferma, predisposizione), fatto di attività semplici e variabili che si prestano a un modello di durata senza memoria. Essendo un $M/M/1$ in senso stretto, questo centro sarà usato come banco di prova esatto nella fase di verifica.



Il suo tempo di servizio, $\mathbb{E}[S] = 3$ s esponenziale, rappresenta un processo automatizzato e regolare di smistamento; l'utilizzazione risultante è molto bassa e il centro non è mai critico.

L'ordine *non viene spacchettato*: il dispatcher applica il routing una sola volta per ordine e inoltra al braccio il job con i suoi attributi (numero di farmaci K , classi degli articoli, canale di provenienza). Il numero di farmaci per ordine è modellato come

$$K = \max(1, \text{round}(\text{Exp}(2,71))), \quad \mathbb{E}[K] \approx 2,86,$$

cioè una esponenziale di media 2,71 arrotondata e forzata ad almeno un farmaco (la coda destra lunga rappresenta gli ordini multi-farmaco). La classe di ciascuno dei K articoli è estratta con probabilità proporzionale alla capacità S_c della classe (cfr. Inventory System), in modo che ogni classe abbia la stessa copertura relativa di scorta.

Logica di smistamento (routing probabilistico)

Il dispatcher instrada ogni ordine cliente ai due bracci secondo uno **scheduling probabilistico** con probabilità fisse:

$$p_{b1} = 0,20 \text{ (Braccio Uno)}, \quad p_{b2} = 0,80 \text{ (Braccio Due)}.$$

La quota verso Braccio Uno è deliberatamente bassa perché quel braccio è già impegnato dai rifornimenti: come mostrato nel flusso forzato, il

solo lavoro di carico assorbe circa il 74% della sua capacità alla domanda media, per cui quote cliente elevate lo renderebbero instabile.

Finestra protetta (carico). Nei **primi 10 minuti di ogni ciclo di revisione delle scorte** (ciclo da 30 minuti) il dispatcher instrada il 100% degli ordini cliente al Braccio Due ($p_{b1} = 0$ in quella finestra), così il Braccio Uno può smaltire senza concorrenza i carichi generati dalla revisione appena avvenuta. Si tratta di un routing *tempo-variante deterministico* (schedulato), che mantiene noto il tasso d'ingresso di ciascun braccio per intervallo. Mediando sul ciclo, la quota effettiva di ordini cliente al Braccio Uno è

$$p_{b1}^{\text{eff}} = p_{b1} \cdot \frac{2}{3} \approx 0,133, \quad p_{b2}^{\text{eff}} \approx 0,867,$$

valori usati nelle equazioni di traffico e verificati a posteriori sulle utilizzazioni misurate.

Essendo p_{b1}, p_{b2} probabilità di progetto note, l'instradamento ai bracci rientra nello scheduling astratto: il tasso d'ingresso a ciascun braccio è $\lambda_{\text{centro}} = X_{\text{precedente}} \cdot p$, requisito necessario per l'analisi del flusso forzato e per la validazione per centro.

Braccio Uno (priorità non-preemptive, due code, servizio compound)

- ❑ Arrivi interni da *Dispatcher* (ordini cliente) e da *Magazziniere* (ordini di rifornimento)
- ❑ Due code distinte; disciplina a priorità *non-preemptive* con precedenza ai **prelievi cliente** (FCFS intra-classe)
- ❑ Servizio **prelievo**: somma di K estrazioni da normale troncata $\text{TruncNormal}(10, 5; [5, 20])$ s — una per farmaco, posizioni diverse
- ❑ Servizio **carico**: Q volte *una* estrazione da $\text{TruncNormal}(15, 5; [5, 20])$ s — Q confezioni della stessa classe, stessa posizione
- ❑ Carico **incrementale**: le Q confezioni entrano a banco una alla volta durante il servizio (eventi RESTOCK)

images/immagine_braccio_uno.png

Il **Braccio Uno** serve due flussi:

- **ordini cliente** (prelievo di K farmaci) dal *Dispatcher*;
- **ordini di rifornimento** dal *Magazziniere* (ricostituzione delle scorte a banco).

Le due tipologie entrano in code separate. La disciplina è a priorità **non-preemptive**: un servizio in corso non viene interrotto; al completamento, se è presente un ordine cliente in coda, viene servito *prima* di qualunque carico in attesa. All'interno di ciascuna coda vige FCFS. La precedenza ai prelievi — motivata nel modello concettuale — è la scelta che allinea i tempi di risposta dei clienti instradati a Braccio Uno con quelli del Braccio Due, sfruttando il fatto che il rifornimento, per costruzione della politica (s, S) , tollera l'attesa.

Il tempo di servizio è *generale* e *compound*: per un prelievo è la somma di K estrazioni indipendenti da normale troncata (i K farmaci sono in K posizioni diverse del magazzino robotizzato), mentre per un carico le Q confezioni — della stessa classe, quindi alla stessa posizione — richiedono un tempo Q volte *una singola* estrazione: stessa media per confezione, ma variabilità minore. Con troncatura per reiezione su $[5, 20]$ s le medie effettive per confezione risultano $\mathbb{E}[X_{\text{prel}}] \approx 11,1$ s e $\mathbb{E}[X_{\text{car}}] \approx 13,9$ s.

Perché la normale troncata

- il limite inferiore (5 s) rappresenta il prelievo più rapido (farmaco vicino), quello superiore (20 s) il più lento (farmaco lontano/scomodo);
- la troncatura elimina durate irrealistiche mantenendo la variabilità dovuta a distanza a scaffale, micro-movimentazioni e verifiche;
- la forma unimodale con moda lontana da zero è adatta a task meccanici brevi e ripetitivi, a differenza dell'esponenziale (moda in 0).

Interazione con lo stock

- **Prelievi**: per ciascuno dei K articoli dell'ordine viene richiesta un'unità della rispettiva classe; se la giacenza è a zero l'articolo è perso (OUT-OF-STOCK per-articolo), l'ordine prosegue con gli altri.
- **Carichi**: le Q unità incrementano la giacenza della classe *una alla volta* durante il servizio (eventi RESTOCK equispaziati sul tempo di carico), come avviene fisicamente sul nastro: un prelievo concorrente può così attingere alle unità già caricate, riducendo gli out-of-stock “di tempismo”.

Il servizio di carico resta un blocco unico ai fini di code e utilizzazione (il braccio è occupato per

l'intera durata); il carico incrementale cambia solo l'istante in cui le unità diventano disponibili.

Braccio Due (coda unica, $M/G/1$, servizio compound)

- ❑ Arrivi interni solo dal *Dispatcher* (ordini cliente)
- ❑ Una sola coda con disciplina FCFS
- ❑ Nessun carico/rifornimento dal *Magazziniere*
- ❑ Servizio: somma di K estrazioni da $\text{TruncNormal}(15, 5; [10, 20])$ s, $\mathbb{E}[X] = 15$ s per farmaco
- ❑ $\mathbb{E}[S_{B2}] = \mathbb{E}[K] \cdot 15 \approx 43$ s per ordine
- ❑ Integrazione con *Inventory System* e out-of-stock per-articolo

Ruolo e logica di servizio

Il **Braccio Due** è dedicato esclusivamente al prelievo dei farmaci richiesti dai clienti. A differenza del Braccio Uno non esegue operazioni di rifornimento, quindi non riceve traffico dal Magazziniere e non necessita di priorità: tutti gli ordini entrano in un'unica coda servita FCFS.

Il tempo di prelievo per confezione, **misurato sul robot reale**, è modellato con la normale troncata $\text{TruncNormal}(15, 5; [10, 20])$ — troncatura simmetrica, media effettiva esattamente 15 s — e il servizio di un ordine è la somma di K estrazioni indipendenti. La dizione $M/G/1$ riflette il servente singolo con servizio generale (compound); gli arrivi, pur essendo un flusso interno filtrato dal routing, restano ben approssimati da un processo di Poisson, come confermato in verifica dal confronto con la formula di Pollaczek–Khinchine.

images/immagine_braccio_due.png

Poiché riceve la quota prevalente del traffico cliente ($\approx 87\%$ effettivo) con un *unico* servente, il Braccio Due è il centro critico del percorso clienti: è il primo a saturare all'aumentare di λ sul flusso dei prelievi, ed è il motivo del cap sugli slot di punta del profilo di arrivo. Durante le finestre protette assorbe il 100% dei clienti e la sua coda può allungarsi temporaneamente: è il prezzo, contenuto, pagato per dare respiro al carico del Braccio Uno.

Interazione con stock e out-of-stock

Come per il Braccio Uno, al servizio dell'ordine vengono richieste al banco le unità delle classi dei K articoli; ogni articolo non disponibile è conteggiato come out-of-stock (per-articolo) mentre l'ordine prosegue. Al termine del prelievo l'ordine esce verso la Cassa Pagamento (clienti fisici) o direttamente dal sistema (clienti online).

Cassa Pagamento ($M/M/2$)

- ❑ Arrivi interni: clienti **fisici** in uscita dai bracci (gli online saltano il centro)
- ❑ Coda unica, **2 sportelli**, disciplina FCFS
- ❑ Tempo di servizio esponenziale con media $\mathbb{E}[S] = 60$ s
- ❑ Uscita dal sistema al completamento del pagamento

La Cassa Pagamento chiude il percorso dei clienti fisici: ritirati i farmaci dal robot, il cliente salda l'ordine presso uno dei due sportelli dedicati. Il

servizio (conto, pagamento, scontrino, eventuale busta) è modellato come esponenziale di media 60 s. I clienti online, che hanno già pagato al momento dell'ordine, escono dal sistema direttamente dal braccio: il centro riceve quindi il 95% del flusso complessivo. Con due sportelli l'utilizzazione per servente resta moderata ($\approx 0,54$ alla domanda media) e il centro non è critico; il suo contributo al tempo di risposta end-to-end dei clienti fisici è però non trascurabile (≈ 85 s di permanenza) ed è per questo incluso nel modello.

Magazziniere ($M/G/2$, servizio proporzionale alla quantità)

- ❑ Arrivi interni dall'*Inventory System* (ordini di rifornimento, spezzati in colli da al più 20 unità)
- ❑ Coda unica con $n = 2$ serventi in parallelo
- ❑ Tempo di servizio **proporzionale alla quantità**: $S(Q) = \sum_{i=1}^Q \text{Exp}(18)$ — circa 18 s di handling per confezione
- ❑ Uscita: l'ordine di carico, con la sua quantità Q , è instradato alla coda rifornimenti del **Braccio Uno**



Ruolo e logica di servizio

Il **Magazziniere** è un centro multi-server a coda unica: riceve gli ordini di rifornimento generati dalla revisione periodica delle scorte. Un riordino di quantità complessiva elevata viene **spezzato in colli da al più 20 unità** ($\leq \text{MAX_REORDER_CHUNK}$), così i due serventi possono lavorare in parallelo e il Braccio Uno riceve carichi di dimensione contenuta invece di un unico blocco monolitico; l'ordine *logico* della classe resta uno solo (regola del singolo ordine pendente), i colli ne sono la suddivisione operativa.

Tempo di servizio: perché $\propto Q$

Il lavoro del magazziniere è fisicamente *per confezione*: prelevato il collo (master carton) dal

magazzino interno, deve aprire il confezionamento di trasporto, estrarre e aprire i fardelli terziari in cellophane (6–12 scatoline ciascuno), prelevare ogni singola scatolina, verificarla e posarla sul nastro di carico. Il servizio è quindi modellato come somma di Q tempi esponenziali indipendenti di media 18 s — il *tempo medio di handling per confezione*, comprensivo delle aperture ammortizzate — e il servente resta occupato per l'intera durata. Un modello con tempo per ordine costante sottostimerebbe l'occupazione del magazziniere proprio sui riordini grandi.

Tandem produttore–consumatore

Sul percorso di rifornimento agiscono due agenti in sequenza su ciascuna confezione:

$$\underbrace{\approx 18 \text{ s/conf.}}_{\text{magazziniere (alimenta)}} \longrightarrow \text{nastro} \longrightarrow \underbrace{\approx 13,9 \text{ s/conf.}}_{\text{Braccio Uno (carica)}}$$

Poiché il ritmo di alimentazione umano è più lento del ritmo di carico robotico, il consumatore è più veloce del produttore: il nastro non accumula e l'ipotesi di buffer illimitato sul modulo di carico

è una semplificazione fedele ai fatti. Un limite fisico alla coda dei rifornimenti esiste comunque per costruzione: con la regola del singolo ordine pendente per classe, il lavoro arretrato non può superare $\sum_c (S_c - s_c)$ unità.

Con due serventi, l'utilizzazione del magazziniere alla domanda media è $\approx 0,49$ per servente: il centro assorbe i burst di riordino generati dalle revisioni senza diventare collo di bottiglia, fungendo di fatto da “spaziatore” che distribuisce nel tempo i carichi verso il Braccio Uno.

Inventory System (politica (s, S) per 5 classi, lost-sales)

- 5 classi di farmaco, capacità a banco $S = \{80, 70, 60, 55, 35\}$ unità ($\sum_c S_c = 300 =$ slot fisici del banco robotizzato)
- Politica (R, s, S) : revisione periodica ogni $R = 30$ minuti; se $l_c \leq s_c$ si ordina $S_c - l_c$ (order-up-to)
- **Un solo ordine pendente per classe**
- **Lost-sales**: domanda insoddisfatta persa, $l_c(t) \geq 0$; metrica di servizio $P(\text{OOS})$ per articolo
- Domanda per classe proporzionale alla capacità: $P(\text{classe } c) = S_c / \sum S = \{26,7\%, 23,3\%, 20,0\%, 18,3\%, 11,7\%\}$
- Le soglie s_c sono le **variabili di ottimizzazione** (le S_c sono fisse, vincolate dalla capacità fisica)

Il sottosistema segue lo schema del *Simple Inventory System* di Leemis-Park, con tre estensioni che lo ancorano al sistema reale: (i) la **domanda non è un processo esogeno indipendente** ma è generata dal flusso clienti simulato (compound: K articoli per ordine, multi-classe); (ii) il **lead time di consegna è endogeno**: emerge dal percorso

magazziniere $\rightarrow$ Braccio Uno (code e priorità comprese) invece che da una distribuzione assegnata; (iii) la politica è **lost-sales** anziché backorder, coerente con il contesto farmacia. Per la scelta lost-sales il livello non scende mai sotto zero e la shortage time-averaged è nulla per costruzione: la metrica di servizio è la probabilità di out-of-stock per articolo, vincolata al 5%.

La revisione periodica è un evento artificiale schedato (avviene anche quando non genera ordini). Il periodo $R = 30$ minuti è una variabile di controllo della politica: un R più corto riduce gli out-of-stock ma aumenta i costi amministrativi d'ordine; il confronto quantitativo $R = 30$ vs $R = 60$ minuti è parte della ricerca di configurazione dell'inventario.

Come discusso nel modello di costo, l'asimmetria shortage/holding ($\approx 500\times$) rende l'inventario un *guardrail*: le soglie s_c ottime sono le minime che coprono la domanda della classe durante il lead time di rifornimento (più margine per le classi piccole, più variabili in proporzione), non le massime possibili — oltre la copertura del lead time l'out-of-stock non scende più e si pagano solo giacenza e micro-riordini continui.

Matrice di Routing

Di seguito la matrice di routing del sistema:

$$\mathbf{P} = \begin{matrix} & \text{ext} & 1 & 2 & 3 & 4 & 5 & 6 & 7 \\ \begin{matrix} \text{ext} \\ 1 \\ 2 \\ 3 \\ 4 \\ 5 \\ 6 \\ 7 \end{matrix} & \begin{pmatrix} 0 & P_c & P_o & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & p_{b1} & p_{b2} & 0 & 0 \\ P_o & 0 & 0 & 0 & 0 & 0 & 0 & P_c \\ P_o & 0 & 0 & 0 & 0 & 0 & 0 & P_c \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \end{pmatrix} \end{matrix}$$

- **ext**: Esterno
- **1**: Casse Fisiche
- **2**: Cassa Online
- **3**: Dispatcher
- **4**: Braccio Uno
- **5**: Braccio Due
- **6**: Magazziniere
- **7**: Cassa Pagamento

Il Magazziniere (nodo 6) riceve gli ordini di rifornimento λ_{IS} generati dall'Inventory System e instrada tutti i carichi verso il Braccio Uno (nodo 4, coda dedicata). Dai bracci (nodi 4 e 5) l'ordine prosegue verso la Cassa Pagamento se il cliente è fisico (probabilità P_c), oppure esce dal sistema se il cliente è online (probabilità P_o); i carichi di rifornimento serviti dal Braccio Uno terminano a banco (uscita dal punto di vista dei job). La riga 4 della matrice si riferisce ai soli job cliente.

Parametri

$\mathbf{P}_c$: probabilità di entrare nel sistema accedendo alle Casse Fisiche

$$P_c = 0,95$$

$\mathbf{P}_o$: probabilità di entrare nel sistema accedendo alla Cassa Online

$$P_o = 1 - P_c = 0,05$$

Un cliente, terminato il servizio alla cassa, raggiunge sempre il dispatcher (probabilità 1).

$\mathbf{p}_{b1}$: probabilità (di progetto) di instradare un ordine cliente a Braccio Uno, $p_{b1} = 0,20$ (quota effettiva 0,133 per via della finestra protetta).

$\mathbf{p}_{b2}$: probabilità di instradare un ordine cliente a Braccio Due, $p_{b2} = 0,80$ (quota effettiva 0,867).

Le intensità di arrivo cambiano per fascia oraria: si assume un flusso di richieste variabile e si usa la matrice di routing per propagarne gli effetti sui centri interni.

3.0.1 Arrivi per fascia oraria

λ_i per ogni i-esima fascia oraria
08:00 – 08:30 $\Rightarrow \lambda_1 = 0,007050 \text{ req/s}$
08:30 – 09:00 $\Rightarrow \lambda_2 = 0,008615 \text{ req/s}$
09:00 – 09:30 $\Rightarrow \lambda_3 = 0,015500 \text{ req/s}$
09:30 – 10:00 $\Rightarrow \lambda_4 = 0,018335 \text{ req/s}$
10:00 – 10:30 $\Rightarrow \lambda_5 = 0,019800 \text{ req/s}$
10:30 – 11:00 $\Rightarrow \lambda_6 = 0,016200 \text{ req/s}$
11:00 – 11:30 $\Rightarrow \lambda_7 = 0,022200 \text{ req/s}$
11:30 – 12:00 $\Rightarrow \lambda_8 = 0,025500 \text{ req/s}^{(*)}$
12:00 – 12:30 $\Rightarrow \lambda_9 = 0,024935 \text{ req/s}$
12:30 – 13:00 $\Rightarrow \lambda_{10} = 0,020400 \text{ req/s}$
13:00 – 13:30 $\Rightarrow \lambda_{11} = 0,012900 \text{ req/s}$
13:30 – 14:00 $\Rightarrow \lambda_{12} = 0,015765 \text{ req/s}$
14:00 – 14:30 $\Rightarrow \lambda_{13} = 0,016135 \text{ req/s}$
14:30 – 15:00 $\Rightarrow \lambda_{14} = 0,013200 \text{ req/s}$
15:00 – 15:30 $\Rightarrow \lambda_{15} = 0,012000 \text{ req/s}$
15:30 – 16:00 $\Rightarrow \lambda_{16} = 0,014665 \text{ req/s}$
16:00 – 16:30 $\Rightarrow \lambda_{17} = 0,017700 \text{ req/s}$
16:30 – 17:00 $\Rightarrow \lambda_{18} = 0,021635 \text{ req/s}$
17:00 – 17:30 $\Rightarrow \lambda_{19} = 0,024000 \text{ req/s}$
17:30 – 18:00 $\Rightarrow \lambda_{20} = 0,025500 \text{ req/s}^{(*)}$
18:00 – 18:30 $\Rightarrow \lambda_{21} = 0,025500 \text{ req/s}^{(*)}$
18:30 – 19:00 $\Rightarrow \lambda_{22} = 0,024900 \text{ req/s}$
19:00 – 19:30 $\Rightarrow \lambda_{23} = 0,025500 \text{ req/s}$
19:30 – 20:00 $\Rightarrow \lambda_{24} = 0,020000 \text{ req/s}$
(*) slot di punta limitato al cap 0,0255 req/s

Media giornaliera del profilo: $\bar{\lambda} = 0,018664 \text{ req/s}$ (≈ 806 clienti/giorno); media del profilo osservato prima del cap: $0,0190975 \text{ req/s}$, usata come tasso costante di riferimento nelle simulazioni a orizzonte infinito.

4 Modello computazionale

Il modello è implementato in Java come **simulazione a eventi discreti** secondo il paradigma *next-event* (Leemis–Park): il tempo avanza da un evento al successivo estraendo dalla lista degli eventi futuri quello con timestamp minimo, aggiornando lo stato e le statistiche integrate, e programmando gli eventi conseguenti. Lo *stato computazionale* comprende, oltre al vettore di stato fisico $x(t)$ del modello concettuale, la lista degli eventi futuri e gli accumulatori statistici: è l'informazione minima che consente di proseguire la run da un istante qualunque.

I tipi di evento coincidono con quelli descritti nel modello concettuale (ARRIVAL, DEPARTURE, TIMECHANGE, SLOTCHANGE, RESTOCK, COMPLETION, SAMPLING, più ABANDON presente ma mai schedato). Ogni centro è un oggetto che incapsula coda (o code), serventi e generazione del proprio tempo di servizio; gli *handler* degli eventi realizzano l'instradamento della matrice di routing e l'interazione con l'inventory system. Le statistiche sono raccolte in due famiglie: *time-averaged* (aree integrate $\int X(t) dt$: popolazioni medie, utilizzazioni, livello medio di scorta), aggiornate a ogni evento, e *job-averaged* (tempi di risposta e di attesa), accumulate al completamento dei job. L'utilizzazione dei bracci è integrata dal **tempo di occupazione effettivo** del servente ($\int \mathbf{1}_{\{\text{busy}\}} dt$), così da restare per costruzione in $[0, 1]$ anche con i servizi compound.

Generazione dei numeri casuali

Si usa il generatore di **Lehmer** della libreria del corso (Rngs): $x_{i+1} = ax_i \bmod m$ con $m = 2^{31}-1$ e

moltiplicatore a periodo pieno $a = 48271$. Il generatore fornisce **256 stream disgiunti** (jump multiplier $A_{256} = 22925$), e la convenzione adottata — prescritta dal corso — è **uno stream dedicato per ogni componente stocastica**: arrivi esterni, scelta del canale fisico/online, classe di ciascun farmaco, numero di farmaci K , instradamento ai bracci, e un tempo di servizio per ciascun centro (13 stream in totale). Questo garantisce che le componenti siano statisticamente indipendenti e riproducibili, e abilita l'uso dei *common random numbers* nei confronti tra configurazioni.

Indipendenza delle repliche e dei batch

Nell'orizzonte finito l'esperimento consiste in n **repliche indipendenti** della giornata: **plantSeeds** è chiamata **una sola volta, fuori dal loop** delle repliche, e ogni replica prosegue dallo *stato finale* degli stream della replica precedente. Le repliche usano così sottosequenze disgiunte del generatore — nessuna sovrapposizione, nessuna correlazione indotta — senza mai reinizializzare gli stream dentro il loop. Nell'orizzonte infinito l'indipendenza (approssimata) è tra *batch*: lo stato iniziale di un batch è lo stato finale del precedente, e la decorrelazione è garantita dalla scelta della dimensione di batch (sezione sulla calibrazione). Le stime intervallari usano in entrambi i casi la t di Student con $\alpha = 0,05$.

Per ogni esperimento il programma scrive su file una serie per metrica e per centro (medie di finestra con intervallo di confidenza nel finito, medie di batch nell'infinito), da cui sono prodotti i grafici e le tabelle delle sezioni successive.

5 Analisi del Flusso Forzato

Perché la rete è fuori dal product-form

Prima di procedere è utile chiarire perché non si può ricorrere a una soluzione analitica in forma-prodotto (Jackson/BCMP) dell'intera rete. Un ordine cliente entra come **un solo job** (la richiesta di K farmaci è contenuta nel *tempo di servizio* del braccio, non moltiplica il numero di job): non c'è quindi alcuna replica di clienti. La rete resta comunque fuori dalle ipotesi BCMP per quattro motivi strutturali:

- **servizio generale (compound) ai brac-**

ci: il tempo di prelievo è una somma di K estrazioni da normale troncata $\Rightarrow$ centri $M/G/1$ (FCFS con servizio non esponenziale viola BCMP);

- **priorità non-preemptive** al Braccio Uno (due code, prelievo e carico);
- **serventi eterogenei / skill-based**: il Braccio Uno serve sia prelievi sia carichi, il Braccio Due solo prelievi (configurazione a serventi con vincoli di classe);

□ **casce** $M/M/m$ **eterogenee** (i cinque farmacisti hanno tassi diversi).

La validazione sarà quindi condotta *per-centro* (confronto con i modelli analitici $M/M/1$, $M/M/m$, $M/G/1$ Pollaczek–Khinchine) e tramite le leggi operazionali, non su una forma chiusa globale.

Considerazioni

L'analisi del flusso forzato che segue è di tipo *operazionale* (leggi di Little e dell'utilizzazione): richiede solo i tassi di visita e i tempi medi di servizio, ed è dunque valida *indipendentemente dalla forma delle distribuzioni* di servizio — anche con tempi generali ai bracci e serventi eterogenei alle casce. Serve a individuare il collo di bottiglia e a prevedere le utilizzazioni ρ_i : se qualche $\rho_i \geq 1$ il sistema diverge, e ciò deve concordare con l'analisi del transitorio.

Equazioni di traffico

Con l'instradamento probabilistico fisso, le equazioni di traffico sono lineari e *senza fattori di replica*:

$$\begin{cases} \lambda_O &= \lambda P_o \\ \lambda_C &= \lambda P_c \\ \lambda_D &= \lambda_O + \lambda_C = \lambda \\ \lambda_M &= \lambda_{IS} \\ \lambda_{B1} &= p_{b1}^{\text{eff}} \lambda_D + \lambda_M \\ \lambda_{B2} &= p_{b2}^{\text{eff}} \lambda_D \\ \lambda_P &= P_c \lambda \end{cases}$$

5.1 Analisi

Al fine di individuare il collo di bottiglia del sistema, consideriamo per ciascun centro la **domanda di servizio per cliente entrante**

$$D_i = \frac{v_i \mathbb{E}[S_i]}{m_i}, \quad v_i = \frac{\lambda_i}{\lambda},$$

normalizzata sul numero di serventi m_i : l'utilizzazione prevista a tasso λ è $\rho_i = \lambda D_i$ e il cen-

La tabella mette in evidenza una struttura a **due colli di bottiglia**, uno per ciascuno dei flussi che attraversano il sistema.

Sul percorso dei clienti il centro critico è il **Braccio Due**: pur avendo un servizio per ordine inferiore alle casce, riceve circa l'87% dei prelievi

Parametri:

- arrivo totale esterno λ , ripartito in $P_o = 0,05$ verso la Cassa Online e $P_c = 0,95$ verso le Casce fisiche;
- tutta la domanda servita alle casce raggiunge il Dispatcher (abbandoni disattivati);
- Dispatcher: instrada l'*intero* ordine con quote effettive $p_{b1}^{\text{eff}} = 0,133$, $p_{b2}^{\text{eff}} = 0,867$ (probabilità di progetto 0,20/0,80 mediate con la finestra protetta); il numero K di farmaci entra nel tempo di servizio del braccio, non nelle equazioni di traffico;
- Magazziniere: gli ordini di rifornimento λ_{IS} generati dall'inventario confluiscono nella sola coda di carico del Braccio Uno (nessun flusso verso Braccio Due);
- Cassa Pagamento: riceve i soli clienti fisici in uscita dai bracci.

Il termine K non compare qui: essendo interno al tempo di servizio, entra nella *domanda* $D_i = v_i \mathbb{E}[S_i]$ tramite $\mathbb{E}[S_i]$, non come moltiplicatore di job. Analogamente il flusso di rifornimento, essendo asservito alle vendite dalla politica order-up-to, è espresso come *lavoro per cliente*: a regime ogni unità venduta è ricaricata una volta, quindi il carico porta $\mathbb{E}[K]$ confezioni per cliente al Braccio Uno e $\mathbb{E}[K]$ confezioni per cliente al Magazziniere.

tro con D_i massimo determina la massima portata sostenibile $X_{\max} = 1/D_{\max}$. I tempi medi di servizio derivano dai parametri del modello: $\mathbb{E}[K] = 2,86$ farmaci/ordine, $\mathbb{E}[X]$ per confezione pari a 15 s (Braccio Due), 11,1 s (prelievo Braccio Uno), 13,9 s (carico) e 18 s (handling magazzino).

con un *unico* servente, mentre le casce distribuiscono il carico su cinque farmacisti. La sua domanda $D_{B2} = 37,2$ s/cliente implica $X_{\max} \approx 0,0269$ req/s: è il vincolo che ha motivato il **cap dei tre slot di punta** a $\lambda = 0,0255$ req/s, valore al quale l'utilizzazione prevista del braccio è 0,95 — al lim-

Centro	m_i	v_i	$\mathbb{E}[S_i]$ (s)	D_i (s)	$\rho_i(\bar{\lambda})$	$\rho_i(0,0255)$
Casse Farmacia	5	0,95	135 (media)	25,7	0,49	0,65
Cassa Online	1	0,05	60	3,0	0,06	0,08
Dispatcher	1	1	3	3,0	0,06	0,08
Braccio Uno (prelievi)	1	0,133	$\mathbb{E}[K] \cdot 11,1 = 31,9$	4,3	0,82	≈ 1 (*)
Braccio Uno (carico)		—	$\mathbb{E}[K] \cdot 13,9$ per cliente	38,9		
Braccio Due	1	0,867	$\mathbb{E}[K] \cdot 15 = 43,0$	37,2	0,71	0,95
Magazziniere	2	—	$\mathbb{E}[K] \cdot 18$ per cliente	25,8	0,49	0,66
Cassa Pagamento	2	0,95	60	28,5	0,54	0,73

Tabella 1: Analisi del flusso forzato: domande di servizio per cliente e utilizzazioni previste alla domanda media ($\bar{\lambda} = 0,0190975$ req/s) e al cap di picco (0,0255 req/s). Il lavoro di carico e del magazziniere è espresso per cliente servito (a regime le unità caricate eguagliano le vendite, scontate della quota out-of-stock $\approx 2\%$). (*): si veda la discussione sulla saturazione della catena di rifornimento.

ite della zona di lavoro accettabile per un servente singolo.

Sul sistema completo, includendo il rifornimento, la voce di lavoro più grande è però quella del **Braccio Uno**: il solo carico vale ≈ 39 s/cliente (ogni unità venduta va ricaricata, a 13,9 s l'una), che sommato ai prelievi porta $D_{B1} \approx 43$ s/cliente e $X_{\max} \approx 0,023$ req/s. Alla domanda media il centro è stabile ($\rho \approx 0,82$), ma un tasso di picco *sostenuto* oltre 0,023 eccede la capacità della catena di rifornimento. Il sistema non diverge — la politica lost-sales agisce da valvola: quando il carico non tiene il passo le scorte calano, una parte della domanda va in out-of-stock e il lavoro di carico si riduce di conseguenza — ma il prezzo è pagato in perdite di servizio. Questo fenomeno, qui

previsto analiticamente, riemergerà con precisione negli esperimenti a orizzonte infinito sulle fasce di punta (attività 5), dove nessuna configurazione di personale riesce a rispettare il vincolo sull'out-of-stock: il collo lì non è lo staffing ma la capacità di carico del robot. Nella giornata reale, però, i picchi durano 30–60 minuti e il banco pieno li assorbe: il rispetto del vincolo va giudicato sull'orizzonte finito.

Alla domanda media $\bar{\lambda}$ tutti i ρ_i sono inferiori a 1 (massimo: Braccio Uno, 0,82): il flusso forzato **prevede l'esistenza dello stato stazionario**, previsione che l'analisi del transitorio dovrà confermare. Le utilizzazioni qui previste saranno confrontate con quelle misurate nella sezione di verifica.

6 Verifica

La verifica risponde alla domanda: *il modello computazionale realizza correttamente il modello delle specifiche?* Non potendo disporre di una forma chiusa dell'intera rete, la verifica è condotta a pezzi, su quattro livelli: bilanci di conteggio, leggi operazionali, confronto per-centro con i modelli analitici, e un test degenerato del sottosistema d'inventario contro il modello canonico di Leemis e Park.

Bilanci di conteggio

In ogni esperimento valgono esattamente le identità di conservazione. Sui *job* (medie per replica, 128 repliche dell'orizzonte finito, scenario ottimizzato dell'attività 6): arrivi 810,22 = serviti 810,22, con abbandoni = 0 — nessun job perso o duplicato nel percorso. Sugli *articoli*: domandati 2324,11 = venduti 2232,62 + persi per out-of-stock 91,49; inoltre venduti — caricati = scorta iniziale — scorta finale (il banco parte pieno e chiude la giornata parzialmente scarico). Il rapporto articoli/clienti osservato, 2324,11/810,22 = 2,868, riproduce $\mathbb{E}[K] = 2,863$ del modello di input.

Leggi operazionali (Little)

Il tempo di risposta di sistema è calcolato in *tre modi indipendenti*: (A) somma dei tempi per centro pesata sui flussi, (B) media dei tempi individuali ingresso-uscita, (C) legge di Little applicata all'area integrata della popolazione ($\mathbb{E}[N]/X$). I tre

stimatori coincidono entro frazioni di punto percentuale in tutte le run — una verifica incrociata che copre contemporaneamente contatori, aree e timestamp. A livello di centro, ad esempio, per le casse (orizzonte infinito): $\lambda_C \cdot W_q = 0,018143 \cdot 5,23 = 0,0949$ contro $\mathbb{E}[N_q] = 0,0948 \pm 0,0106$ misurato.

Confronto con i modelli analitici per centro

I centri markoviani della rete ammettono formule esatte, e per il Braccio Due — servente singolo con servizio generale — vale Pollaczek–Khinchine:

$$W_q = \frac{\lambda \mathbb{E}[S^2]}{2(1 - \rho)},$$

dove i momenti del servizio compound $S = \sum_{i=1}^K X_i$ si ottengono analiticamente dai parametri di input:

$$\mathbb{E}[S] = \mathbb{E}[K] \mathbb{E}[X] = 42,95 \text{ s},$$

$$\mathbb{E}[S^2] = \mathbb{E}[K] \text{Var}(X) + \mathbb{E}[K^2] \mathbb{E}[X]^2 \approx 3382 \text{ s}^2,$$

con $\mathbb{E}[K] = 2,863$, $\mathbb{E}[K^2] = 14,94$, $\mathbb{E}[X] = 15 \text{ s}$, $\text{Var}(X) = 7,28 \text{ s}^2$ (normale troncata su $[10, 20]$). Per la Cassa Pagamento ($M/M/2$) si usa la formula di Erlang-C; gli arrivi a valle dei bracci non sono esattamente poissoniani, quindi l'accordo atteso è approssimato. Il confronto usa la run a orizzonte infinito di riferimento ($\lambda = 0,0190975$, 64 batch da 1024, intervalli al 95%).

Centro	Modello	Metrica	Analitico	Simulato (IC 95%)
Cassa Online	$M/M/1$	$\mathbb{E}[T]$ (s)	63,65	$63,80 \pm 2,01$
		$\mathbb{E}[N_q]$	0,0035	$0,0031 \pm 0,0007$
Dispatcher	$M/M/1$	$\mathbb{E}[T]$ (s)	3,182	$3,179 \pm 0,025$
		$\mathbb{E}[N_q]$	0,0035	$0,0034 \pm 0,0002$
Cassa Pagamento	$M/M/2$ (Erlang-C)	$\mathbb{E}[T]$ (s)	85,3	$84,20 \pm 2,00$
		$\mathbb{E}[N_q]$	0,458	$0,439 \pm 0,031$
Braccio Due	$M/G/1$ (P–K)	$\mathbb{E}[T]$ (s)	139,7	$138,51 \pm 6,39$

Tabella 2: Verifica per centro: valori analitici (dai parametri di input del modello) contro stime di batch means. Tutti i valori analitici cadono negli intervalli di confidenza simulati.

L'accordo è entro l'intervallo di confidenza per Braccio Uno e Cassa Pagamento, ed entro il 3% per gli altri centri, con scarti spiegabili dal mod-

ello stesso. Per le **casse** la previsione 0,490 usa la media aritmetica dei cinque tempi di servizio (135 s), ma con serventi *eterogenei* i farmacisti

Centro	ρ previsto (flusso forzato)	ρ misurato (IC 95%)
Casse Farmacia	0,490	$0,4684 \pm 0,0050$
Braccio Uno	0,816	$0,8167 \pm 0,0073$
Braccio Due	0,711	$0,7053 \pm 0,0074$
Magazziniere	0,492	$0,4786 \pm 0,0040$
Cassa Pagamento	0,544	$0,5433 \pm 0,0072$

Tabella 3: Utilizzazioni previste dal flusso forzato contro utilizzazioni misurate (orizzonte infinito, $\lambda = 0,0190975$).

più veloci completano più job dei lenti: il tempo di servizio efficace pesato sull’uso è ≈ 129 s e l’utilizzazione media ne risulta lievemente inferiore — è la sottigliezza per cui, con serventi a velocità diverse, la popolazione non basta e conta *quali* serventi sono occupati. Per il **magazziniere** lo scarto ($-2,7\%$) corrisponde alla quota di domanda persa per out-of-stock ($\approx 2\%$), che non genera rifornimento. La previsione del Braccio Uno — costruita sommando lavoro di prelievo e di carico — centra il valore misurato: conferma sia le quote effettive di routing (0,133/0,867, finestra protetta inclusa) sia il modello di lavoro “una confezione caricata per unità venduta”.

Test degenerato dell’inventario (contro Leemis–Park)

Il sottosistema (s, S) è stato verificato **contro l’implementazione canonica del Simple Inventory System** di Leemis e Park (Sis3): l’in-

ventario del modello è collassato al caso canonico — una sola classe, domanda Poisson esogena indipendente, revisione periodica, lead time esogeno $U(0, 1)$, parametri scelti in modo da non produrre mai stockout, così che lost-sales e backlogging coincidono — e pilotato con la *stessa identica realizzazione* di numeri casuali (stesso generatore, stessi stream) di un’implementazione fedele del loop di Sis3. Le statistiche canoniche — domanda, unità ordinate, numero di setup, integrale di giacenza, livello finale e minimo — coincidono **esattamente** (scarto relativo nullo, integrale di holding identico alla quarta cifra decimale) su tre combinazioni seed/parametri. Il test certifica la meccanica della politica (condizione di riordino, order-up-to, ordine pendente, integrazione della giacenza); le dinamiche accoppiate che il caso degenero non copre (lead time endogeno, domanda multi-classe) sono coperte dai bilanci di conteggio e dal check di flusso discusso in validazione.

7 Validazione

La validazione risponde alla domanda complementare: *il modello rappresenta adeguatamente il sistema reale?* Conviene affrontarla distinguendo, tra i parametri del modello, quelli **misurati sul campo** da quelli **assunti**. Le tre sorgenti stocastiche dominanti — il profilo degli **arrivi** dall’esterno, i **tempi di servizio delle casse** e i **tempi di servizio dei bracci robotici** — provengono da **misurazioni condotte presso una farmacia reale** dotata di sistema Gollmann; i restanti parametri (tempi del dispatcher e delle casse di pagamento, handling del magazziniere, soglie e costi d’inventario, probabilità di instradamento e distribuzione del numero di farmaci per ordine) sono invece *assunzioni ragionate*, coerenti con la logica operativa del sistema e con la letteratura.

Questa distinzione ha un peso metodologico. Gli input che governano il carico dei centri critici — gli arrivi e i tempi di servizio di casse e bracci, cioè proprio le grandezze da cui dipendono utilizzazioni, individuazione del collo di bottiglia e tempi di risposta — sono *ancorati al dato reale*, non inventati: il modello è dunque validato alla sorgente nelle sue componenti più determinanti. Ciò che manca, e che non è stato possibile reperire, sono le **tracce di esercizio end-to-end** (i tempi reali di attraversamento, cliente per cliente) contro cui confrontare direttamente l’*output* della simulazione. In loro assenza la validazione dell’output si fonda su quattro evidenze indirette: plausibilità dei valori a fronte dell’esperienza operativa, coerenza del comportamento tra fasce orarie, check di flusso del sottosistema d’inventario, e ro-

alle casse: preserva la validazione markoviana in forma chiusa ed è *conservativa* (a parità di media sovrastima le attese se la variabilità reale è minore), con la consapevolezza — dichiarata — che il bias cresce con l'utilizzazione e spinge l'ottimizzazione dello staffing verso il sovra-servizio, mai verso il sotto-dimensionamento.

Routing fisso contro overflow

Infine, la scelta del routing probabilistico fisso in luogo della politica overflow stato-dipendente (implementata e disponibile nel codice come alternati-

va) è stata valutata per confronto simulativo: nessuno split fisso replica l'utilizzazione auto-adattiva che l'overflow produce sul Braccio Uno — l'overflow “riempie” il braccio nei momenti di scarico — ma gli split stabili producono tempi di risposta di sistema comparabili o migliori, e solo il routing a probabilità note rende possibili l'analisi del flusso forzato e la verifica per centro appena mostrate. È il compromesso classico tra fedeltà di una politica adattiva e trattabilità del modello, risolto a favore della seconda e documentato qui come scelta di simulazione.

8 Il piano sperimentale: otto attività in due fasi

La campagna sperimentale è organizzata in **otto attività numerate**, eseguite in quest'ordine e raggruppate in due fasi (la numerazione rispecchia l'organizzazione del codice e dei dati dello studio):

- **Fase I — il sistema attuale (attività 1–3)**: stabilire che il modello converge, tarare gli strumenti di misura dell'orizzonte infinito, e misurare costi e servizio della gestione attuale (*baseline*);
- **Fase II — l'ottimizzazione (attività 4–8)**: scegliere la politica d'inventario e lo staffing per fascia, ricomporre le scelte negli scenari ottimizzati e quantificare il confronto finale.

Ogni attività si apre con una **scheda** che ne dichiara l'**orizzonte di simulazione**, la domanda a cui risponde e l'esito: la distinzione tra i due orizzonti è il filo conduttore della campagna, e merita di essere fissata subito.

Perché entrambi gli orizzonti, e con quali ruoli


L'oggetto vero dello studio è la **giornata operativa**, e per questo l'orizzonte di riferimento è quello **finito**: la farmacia apre alle 08:00 con il sistema vuoto e il banco pieno, lavora dodici ore con un tasso di arrivo che cambia di fascia in fascia (NSPP), e chiude. Le condizioni iniziali e la non stazionarietà non sono un disturbo da eliminare, ma parte del fenomeno che vogliamo misurare. È in questo contesto — e solo qui — che hanno senso le domande operative dello studio: quanti farmacisti tenere in ciascuna fascia, quale probabilità di out-of-stock si osserva sulla giornata, quanto costa la giornata. Metodologicamente la giornata è una simulazione terminante, che si analizza con **repliche indipendenti**: ripetiamo la giornata $n = 128$ volte, ogni replica fornisce un'osservazione $\bar{x}_i(\tau)$, e da queste ricaviamo la media d'ensemble e l'intervallo di confidenza con la t di Student a $n - 1$ gradi di libertà. Baseline, scenari ottimizzati e confronto finale (attività 3, 6, 7, 8) vivono tutti su questo orizzonte.

L'**orizzonte infinito** entra in gioco per un compito ben preciso e circoscritto: **scegliere il numero di casse e magazzinieri da assegnare a ciascuna fascia oraria**. La difficoltà è che nella giornata reale le fasce si susseguono e si influenzano a vicenda — l'arretrato di una si riversa sulla successiva — rendendo difficile isolare il merito di una singola scelta di staffing. Per aggirare l'ostacolo si “congela” una fascia e la si fa durare per sempre: si tiene il suo λ costante e si porta il sistema a regime, dimenticate le condizioni iniziali (warm-up di 10 000 job, dalla stima del transitorio). Diventa così uno stress test pulito e riproducibile, che rivela a parità di domanda quale configurazione regge e a che costo. La stessa simulazione a regime serve anche, in secondo piano, a caratterizzare le prestazioni stazionarie e a verificare il modello contro le formule analitiche (sezione Verifica). Il regime si stima con i **batch means** (algoritmo 8.4.1 di Leemis–Park): un'unica run lunga divisa in $k = 64$ batch, ciascuno che riparte dallo stato finale del precedente — il che elimina il bias iniziale e rende i batch quasi indipendenti — con l'IC dato dalla t di Student a $k - 1$ gradi di libertà.

I due orizzonti hanno quindi ruoli asimmetrici e complementari: l'infinito *propone* la configurazione di staffing di ciascuna fascia (quella di costo minimo che non diverge, anche dove sotto stress perpetuo qualche vincolo puntuale non è soddisfacibile), mentre il finito *decide* — è il banco di prova su cui la configurazione proposta viene riportata nella giornata reale, dove i picchi durano appena 30–60 minuti e le scorte li assorbono, e dove si verifica se i vincoli di servizio sono davvero rispettati. Nessuna scelta fatta sull'infinito è definitiva finché non supera questa prova sul finito (attività 6–8). In tutti i confronti tra configurazioni (attività 4 e 5) si usano infine i **common random numbers**: ogni configurazione è simulata sulla stessa realizzazione degli stream casuali, così che le differenze osservate siano attribuibili alla scelta e non al caso.

#	Attività	Orizzonte	Domanda	Decisione / output
<i>Fase I — il sistema attuale</i>				
1	Transitorio	INFINITO	il sistema converge? dove finisce il warm-up?	stabile; warm-up = 10 000 job
2	Calibrazione batch	INFINITO	quale b rende affidabili gli IC?	$b = 1024$, $k = 64$
3	Baseline	FINITO	costo e servizio della gestione attuale?	riferimento: 2 726 €/gg
<i>Fase II — l'ottimizzazione</i>				
4	Politica (s, S)	FINITO	quali soglie s_c e quale periodo R ?	$s = \{75, 65, 55, 40, 30\}$, $R = 30'$
5	Staffing per fascia	INFINITO	quante casse/magazzinieri per fascia?	profilo per fascia, 1 364 €/gg
6	Scenario ottimizzato	FINITO	le scelte 4+5 reggono la giornata reale?	2 104 €/gg, OOS 3,94%
7	Scenario con turni	FINITO	e con turni contrattuali realistici?	2 116 €/gg, OOS 3,71%
8	Confronto finale	FINITO	quanto si risparmia, a quale prezzo?	-22,4%, SLA ok, +56 s

Tabella 4: Roadmap del piano sperimentale: le otto attività, l'orizzonte di simulazione di ciascuna e la decisione che produce. Le attività a orizzonte infinito *scelgono*; quelle a orizzonte finito *misurano e verificano* sulla giornata operativa reale.



images/immagine1.png

Figura 1: Descrizione del sistema ad alto livello

images/immagine.jpg




Figura 2: Profilo NSPP degli arrivi $\lambda(t)$, costante a tratti sulle 24 fasce da 30 minuti. In rosso i tre slot di punta (11:30–12:00, 17:30–18:00, 18:00–18:30) limitati al cap $\lambda = 0,0255$ req/s.

images/immagine_flusso_forzato.png

9 Fase I — Il sistema attuale (attività 1–3)

La prima fase non ottimizza nulla: stabilisce che il modello converge (attività 1), tara lo strumento di misura dell'orizzonte infinito (attività 2) e fotografa costi e servizio della gestione attuale (at-

tività 3). La baseline che ne esce è il riferimento — economico e di servizio — contro cui sarà giudicato ogni intervento della fase successiva, incluso il guardrail sul tempo di risposta.

9.1 Attività 1 — Analisi del transitorio

Attività 1 — orizzonte: infinito (preparatoria)	
Domanda	il sistema alimentato a tasso costante converge a uno stato stazionario? Dopo quanti completamenti la memoria dello stato iniziale è persa (warm-up)?
Esito	sistema stabile, nessuna divergenza; warm-up stimato ≈ 440 completamenti $\Rightarrow$ adottati 10 000 job in tutte le run a orizzonte infinito.

L'analisi del transitorio è il **primo controllo di convergenza** dello studio: stabilisce se il sistema, alimentato a tasso costante, raggiunge uno stato stazionario — come previsto dal flusso forzato con tutti i $\rho_i < 1$ — e *dove* termina il transitorio iniziale (warm-up), informazione necessaria alla simulazione a orizzonte infinito. Se un centro fosse instabile le curve divergerebbero e l'analisi steady-state non avrebbe senso.

Metodo

Cinque repliche indipendenti partono dal sistema vuoto con $\lambda = 0,0190975$ req/s costante — lo *stesso operating point* delle run a orizzonte infinito, così che la stima del warm-up sia direttamente riutilizzabile — e inventario nella configurazione conservativa pre-ottimizzazione. Lungo ogni replica si campionano 2000 osservazioni, una ogni 20 completamenti (40 000 job per replica), di tre statistiche: tempo di risposta di sistema, utilizzazione delle casse e popolazione media nel sistema. La

media d'ensemble sulle cinque repliche, tracciata contro il numero di completamenti, mostra il rilassamento del transitorio.

Risultati

Le curve si appiattiscono rapidamente e *non divergono*: il sistema è stabile, in accordo con la previsione operativa. La statistica più lenta a convergere è la popolazione di sistema (≈ 440 completamenti); il tempo di risposta si assesta dopo ≈ 320 e l'utilizzazione dopo ≈ 240 . I valori di regime — tempo di risposta ≈ 363 s, utilizzazione casse $\approx 0,47$, $\mathbb{E}[N] \approx 7,4$ — sono coerenti con il flusso forzato e con le stime di batch means della sezione di verifica ($357,8 \pm 6,2$ s).

Per le run a orizzonte infinito si adotta un **warm-up di 10 000 job**, oltre venti volte la stima: la scelta, deliberatamente cautelativa, costa una frazione trascurabile del tempo di simulazione e mette la stima steady-state al riparo da ogni residuo di bias iniziale.

9.2 Attività 2 — Calibrazione della batch size

Attività 2 — orizzonte: infinito (preparatoria)	
Domanda	quale dimensione di batch b rende i batch means (quasi) indipendenti, e quindi affidabili gli intervalli di confidenza di tutte le run a orizzonte infinito?
Esito	$b = 1024$ con $k = 64$ (test di Chatfield: $\max r_1 = 0,194 < 0,25$, conferme multi-seed), adottata in tutte le run a orizzonte infinito dello studio.

La scelta di (b, k) non cambia la stima puntuale ma la validità dell'intervallo di confidenza: i batch means devono essere approssimativamente scorrelati. Fissato $k = 64$ (il valore raccomandato

in letteratura, ≥ 32), la dimensione b è cercata **per raddoppio**: si parte da $b = 1024$ e si raddoppia finché l'autocorrelazione lag-1 delle serie di batch means non scende sotto la soglia di Chat-




Figura 3: Transitorio del tempo di risposta di sistema (media d'ensemble su 5 repliche, dettaglio sui primi 10 000 completamenti): la curva si assesta dopo ≈ 320 completamenti.

field $2/\sqrt{k} = 0,25$, con un margine prudenziale del 20% ($|r_1| \leq 0,20$) e conferma su seed aggiuntivi. Il test è quello canonico di Leemis e Park (Acs): si controlla il solo lag-1 perché, a b grande, la correlazione residua tra batch adiacenti domina quella ai lag superiori — il lag-1 è quindi un proxy sufficiente dell'indipendenza.

Il criterio è applicato alle serie del tempo di risposta globale e dei centri clienti principali (casse, cassa online, Braccio Due). Risultato: $b = 1024$ **accettata al primo tentativo**, con $\max |r_1| = 0,194$ (serie della cassa online, il centro a traffico più basso e quindi più lento a mescolare) e conferme multi-seed a 0,129 e 0,126. Una scansione esplorativa su $b = 128 \dots 4096$ (tre seed)

mostra che $|r_1|$ è già al livello del rumore statistico ($SE = 1/\sqrt{64} = 0,125$) dalle b più piccole: il sistema decorrela in fretta, e $b = 1024$ è una scelta comoda con ampio margine. Ogni run a orizzonte infinito usa quindi $k \times b = 64 \times 1024 = 65\,536$ job dopo il warm-up.

Un caveat va dichiarato: ripetendo il test al λ di picco (0,0252, dove $\rho_{B2} \approx 0,95$ e il mixing rallenta) $b = 1024$ è marginale — un seed su tre supera di poco la soglia ($|r_1| \approx 0,28$). Gli intervalli di confidenza delle fasce più calde nella ricerca di staffing sono quindi lievemente ottimisti; il *ranking* tra configurazioni, basato sulle stime puntuali con common random numbers, non ne risente.




Figura 4: Stessa statistica sull'intera run da 40 000 completamenti: nessuna deriva, la media fluttua attorno al valore di regime (≈ 363 s, linea tratteggiata). Il marcatore verticale indica i 10 000 job usati come warm-up nell'orizzonte infinito.




Figura 5: Autocorrelazione lag-1 dei batch means al variare della dimensione di batch b (scansione su tre seed, $k = 64$): tutte le serie sono sotto la soglia di Chatfield (0,25, linea rossa) già dalle b piccole; la banda grigia indica l'errore standard $1/\sqrt{k}$ di un processo scorrelato.




Figura 6: Correlogramma (lag 1–16) dei batch means a $b = 1024$ per il tempo di risposta globale: nessun lag supera la soglia, i batch sono assimilabili a osservazioni indipendenti.

9.3 Attività 3 — La baseline: la gestione attuale

Attività 3 — orizzonte: finito (128 repliche)	
Domanda	quanto costa e che qualità di servizio offre la gestione attuale — 5 casse e 2 magazzinieri per tutta la giornata, inventario con regola prudenziale uniforme?
Esito	riferimento del confronto: 2 726 €/giorno (di cui 1 992 di personale), $P(\text{OOS}) = 4,14\%$, $\mathbb{E}[T] = 336$ s; casse sovradimensionate per gran parte della giornata.

Scenario e scelta dell'orizzonte

La baseline riproduce la gestione corrente della farmacia: **5 casse e 2 magazzinieri** attivi dall'apertura alla chiusura, e inventario governato dalla regola uniforme prudenziale $s = \{60, 55, 45, 45, 25\}$ — circa il 75–80% della capacità S per ogni classe, la tipica impostazione “di buon senso” adottata in assenza di analisi quantitativa: uguale per tutte le classi, e alta abbastanza da tenere l'out-of-stock lontano.

L'orizzonte è **finito** per necessità, non per convenzione: la baseline deve essere misurata nelle condizioni in cui il sistema vive davvero — la giornata 08:00–20:00 con il profilo NSPP, il banco pieno all'apertura, i picchi che si formano e si riassorbono — perché è su quella giornata che si formano i costi e si giudicano i vincoli. 128 repliche indipendenti, intervalli di confidenza al 95%, statistiche per finestra da 30 minuti lungo la giornata.

Risultati e commento

Sul piano **economico**: 1 992 €/giorno di personale e 734 di inventario, per un totale di 2 726 €/giorno. Il personale pesa il **73%** del totale: qualunque ottimizzazione sensata deve partire da lì, come anticipato nel modello di costo.

Sul piano del **servizio**: $P(\text{OOS}) = 4,14\%$ — sotto il vincolo del 5%, ma non di molto. È un risultato istruttivo: la regola prudenziale uniforme *tiene*, ma in modo inefficiente — compra copertura anche dove non serve (classi lente) e resta comunque vicina alla soglia dove serve (classi ad alta rotazione nei picchi). Il tempo di risposta end-to-end è $\mathbb{E}[T] = 336$ s ($\approx 5,6$ minuti dall'ingresso in coda alla cassa all'uscita dal pagamento), con il profilo per finestra che cresce nelle fasce di punta e si riassorbe in quelle successive (figura); il delivery lag medio dei rifornimenti è 24 minuti, entro il periodo di revisione. Tutta la domanda è servita (810 clienti/giorno, 2 324 articoli).

Sul piano dell'**efficienza**, la baseline mostra il margine che motiva la Fase II: l'utilizzazione delle casse per fascia oscilla tra 0,3 e 0,6 (figura) — per gran parte della giornata cinque farmacisti servono una domanda da due o tre — mentre i bracci robotici lavorano a 0,7–0,8 nei picchi: il collo del sistema è il robot (capacità fissa), non le casse (leva di costo). La baseline fornisce infine il valore di ancoraggio del **guardrail sul tempo di risposta**: i 336 s rispetto ai quali sarà giudicato il peggioramento ammissibile degli scenari ottimizzati.




Figura 7: Baseline, tempo di risposta di sistema per finestra da 30 minuti (medie su 128 repliche): l'attesa cresce nelle fasce di punta (tarda mattinata e sera) e si riassorbe nelle fasce successive — il comportamento tipico di un sistema non stazionario stabile.




Figura 8: Baseline, utilizzazione delle casse per finestra: con 5 farmacisti sempre attivi l'utilizzazione resta tra 0,3 e 0,6 — il sovradimensionamento fuori picco è il margine economico che la Fase II va a recuperare.

10 Fase II — L'ottimizzazione (attività 4–8)

Con la baseline come riferimento, la seconda fase agisce sulle due leve dichiarate negli obiettivi, in un ordine preciso: **prima l'inventario** (attività 4, a personale pieno, così il guardrail sull'out-of-stock è dimensionato in condizioni di servizio piene e indipendenti dallo staffing), **poi lo staffing** (attività 5, a inventario ormai fissato), quindi la **ri-composizione** delle due scelte sulla giornata reale (attività 6 e 7) e il **confronto economico finale**

(attività 8). Le prime due attività *scelgono* — ciascuna sull'orizzonte adatto alla propria domanda — le ultime tre *verificano e quantificano* sull'orizzonte finito. La verifica congiunta finale non è una formalità: il lead time di rifornimento è endogeno e dipende anche dallo staffing (un braccio più conteso consegna più tardi), quindi la coppia inventario+staffing va sempre rivalidata insieme, ed è ciò che le attività 6–8 fanno.

10.1 Attività 4 — La politica di riordino (s, S)

Attività 4 — orizzonte: finito (16 repliche CRN per configurazione)	
Domanda	quali soglie di riordino s_c per classe, quale periodo di revisione R e quale livello iniziale minimizzano il costo d'inventario rispettando $P(\text{OOS}) \leq 5\%$ sulla giornata?
Esito	$s = \{75, 65, 55, 40, 30\}$, $R = 30$ min, banco pieno all'apertura: $P(\text{OOS}) = 3,36\%$ (minimo osservato), ≈ 675 €/giorno, Pareto-ottima; $R = 60$ min scartato (infeasible).

La prima leva di ottimizzazione è la politica d'inventario: le soglie di riordino s_c per classe, il periodo di revisione R e il livello iniziale del banco. Le capacità S_c sono *fisse* (vincolo fisico del banco robotizzato).

Metodo

Lo spazio esplorato è una griglia sulle soglie per classe (passo 10 unità), incrociata con $R \in \{30, 60\}$ minuti e livello iniziale $f \cdot S$ con $f \in \{0,85, 1,0\}$: 576 configurazioni. Ogni configurazione è valutata con **16 repliche** della giornata a orizzonte finito (profilo NSPP completo, personale pieno, common random numbers), catturando $P(\text{OOS})$, costo d'inventario, tempo di risposta e delivery lag. Si è scelto l'orizzonte finito perché la politica deve reggere il *profilo* giornaliero — i picchi consumano il banco più della media — e perché il costo d'inventario è naturalmente definito sulla giornata. Nessuna funzione di merito aggregata: la selezione avviene sul **fronte di Pareto** costo- $P(\text{OOS})$.

Risultati

Il confronto tra i periodi di revisione è netto: con $R = 60$ minuti nessuna configurazione rispetta il vincolo ($P(\text{OOS})$ minimo $\approx 11\%$) e i costi, dominati dallo shortage, raddoppiano — il banco, con i suoi buffer da poche decine di unità per classe, non copre un'ora di domanda di picco. $R = 30$ **minuti** è quindi il periodo adottato, e su di esso un ampio insieme di configurazioni soddisfa il vincolo del 5%.

Sul fronte di Pareto la configurazione scelta è

$$s = \{75, 65, 55, 40, 30\}, \quad R = 30 \text{ min}, \quad f = 1,0,$$

che realizza il **minimo $P(\text{OOS})$ osservato** (3,36%) con costo d'inventario ≈ 675 €/giorno, ad appena +0,7% dal minimo di costo assoluto: nessuna configurazione è contemporaneamente più economica e con meno perdite (Pareto-ottima). Rispetto alla regola uniforme di partenza ($s \approx 75$ –80% di S per tutte le classi), la ricerca *differenzia per classe*: porta la copertura delle classi 1–3 e 5 vicino alla capacità ($s/S \approx 0,86$ –0,94) e trattiene la classe 4 ($s_4/S_4 \approx 0,73$) — coerentemente con la lettura “a guardrail” del modello di costo: si compra copertura dove il rischio di stockout durante il lead time la richiede, non ovunque. Il tempo di risposta di sistema è risultato, come atteso, insensibile alla politica d'inventario (la variabile agisce sulle perdite, non sulle code dei clienti).

Sul *delivery lag* va registrato un aspetto strutturale: il lag medio (≈ 23 minuti) è inferiore a R , ma nei burst di riordino — quando più classi scattano alla stessa revisione — circa un quarto degli ordini completa il carico oltre la revisione successiva (massimo osservato ≈ 59 minuti). La regola del singolo ordine pendente per classe impedisce l'accumulo (il riordino successivo della classe attende il completamento del precedente) e il $P(\text{OOS})$ resta entro il vincolo: si è quindi assunto come criterio operativo il livello di servizio, e il lag come diagnostica — imporre “lag mai oltre R ” sarebbe stato un vincolo più severo del necessario.




Figura 9: Ricerca della politica (s, S) : costo d’inventario contro $P(\text{OOS})$ per le configurazioni esplorate a $R = 30$ min; la configurazione scelta (evidenziata) è Pareto-ottima e rispetta il vincolo del 5% con il margine più ampio.

10.2 Attività 5 — Lo staffing per fascia oraria

Attività 5 — orizzonte: infinito (96 run 64×1024 , una per fascia $\times$ configurazione)	
Domanda	quante casse e quanti magazzinieri servono in ciascuna delle 12 fasce orarie, a parità d’inventario (fissato dall’attività 4)?
Esito	profilo per fascia: 2–4 casse e 1–2 magazzinieri (mai i 5+2 attuali), personale 1364 €/giorno (−31,5%); nelle 5 fasce di punta scelta best-effort (il limite è la catena di rifornimento, non lo staffing).

La seconda leva — quella economicamente dominante — è il numero di farmacisti alle casse e di magazzinieri attivi in ciascuna delle 12 fasce orarie.

Metodo

Per ogni fascia (con λ pari alla media dei suoi due slot NSPP da 30 minuti) e per ogni combinazione di staffing — casse $\in \{2, 3, 4, 5\}$, magazzinieri $\in \{1, 2\}$, 96 run in totale — si esegue una simulazione a **orizzonte infinito** (64×1024 batch, warm-up 10 000 job, inventario fisso alla configurazione scelta nella sezione precedente). La logica di questa scelta va esplicitata: mantenere il λ di una fascia costante per un tempo infinito equivale a uno **stress test** — decine di giornate consecutive tutte intense come quella fascia — e serve a determinare, a parità di domanda, **la configurazione di costo minimo che non diverge**. Non è, né vuole essere, una verifica degli SLA di giornata: quella spetta all’orizzonte finito sul sistema complessivo, dove i picchi durano 30–60 minuti e il banco li assorbe.

La metrica di scelta è il **costo totale monetiz-**

zato della fascia:

$$C_{tot} = C_{lavoro} + C_{inventario} + C_{attesa},$$

dove C_{lavoro} usa le tariffe del modello di costo (26/18 €/h), $C_{inventario}$ include holding, shortage e ordini, e $C_{attesa} = c_w \cdot N_{clienti} \cdot \mathbb{E}[T]$ monetizza il tempo dei clienti con un *valore del tempo* $c_w = 10$ €/h (ordine di grandezza del 30–50% del salario orario, knob esplicito del modello). Questa costruzione evita lo score a pesi arbitrari: ogni termine è in €/giorno-equivalente, e una configurazione che facesse esplodere le attese non può vincere perché C_{attesa} cresce linearmente in $\mathbb{E}[T]$.

Una configurazione è **ammissibile** se $P(\text{OOS}) \leq 5\%$ e se è **stabile**, ovvero se il throughput misurato regge la domanda offerta ($X \geq 0,9\lambda$). Il filtro di stabilità è essenziale e non ovvio: nelle fasce calde le configurazioni sotto-dimensionate mostrano $P(\text{OOS})$ *artificialmente basso* — con le casse saturate la domanda resta bloccata in coda e non raggiunge mai il banco — ed è proprio il filtro a smascherarle. Nella fascia 18–19, ad esempio, il $P(\text{OOS})$ minimo assoluto (0,11%) appartiene a una configurazione instabile, mentre la migliore configurazione *stabile* è al 12,5%. Tra le ammis-

sibili si sceglie il minimo C_{tot} ; dove nessuna configurazione è ammissibile si adotta la migliore per

costo tra quelle stabili (*best-effort*).

Fascia	(casce, mag)	$E[T]$ (s)	$P(\text{OOS})$	C_{tot} (€)	ρ_{casce}	ρ_{B1}	Stato
08–09	(2,1)	296	0,00%	1341	0,52	0,34	ammissibile
09–10	(3,1)	397	1,16%	2304	0,74	0,73	ammissibile
10–11	(3,1)	439	2,25%	2561	0,79	0,77	ammissibile
11–12	(4,2)	636	8,98%	5080	0,85	0,95	best-effort
12–13	(4,2)	542	6,35%	4277	0,82	0,93	best-effort
13–14	(3,1)	334	0,14%	1976	0,65	0,62	ammissibile
14–15	(3,1)	340	0,16%	2000	0,66	0,64	ammissibile
15–16	(3,1)	317	0,03%	1905	0,61	0,58	ammissibile
16–17	(3,2)	534	1,76%	3076	0,85	0,84	ammissibile
17–18	(4,2)	781	10,92%	6009	0,87	0,97	best-effort
18–19	(4,2)	866	12,54%	6577	0,88	0,97	best-effort
19–20	(4,2)	543	6,59%	4322	0,82	0,93	best-effort

Tabella 5: Configurazione di staffing selezionata per fascia (orizzonte infinito al λ della fascia, C_{tot} in €/giorno-equivalente — confrontabile solo entro la stessa fascia). Le cinque fasce di punta sono *best-effort*: nessuno staffing stabile rispetta il 5% di out-of-stock sotto stress prolungato.

Lettura dei risultati

Nelle fasce ordinarie bastano **2–3 casce e 1 magazzino** (contro i 5+2 della gestione attuale), con casce a utilizzazione sana (0,5–0,8) e vincolo di servizio rispettato con margine. Nelle **cinque fasce di punta** (11–13 e 17–20) nessuna configurazione stabile scende sotto il 5% di out-of-stock: aggiungere casce non aiuta — anzi, immette domanda più in fretta verso un banco che non riesce a ricaricarsi — perché sotto stress prolungato satura la **catena di rifornimento** ($\rho_{B1} \approx 0,93\text{--}0,97$ nella tabella), esattamente come previsto dall’analisi del flusso forzato ($X_{\max}^{\text{carico}} \approx 0,023 < \lambda_{\text{picco}}$). In quelle fasce la scelta cade sul minimo costo tra le configurazioni stabili, (4,2), e la verifica del vincolo è rimandata — correttamente — alla giornata

intera: nell’orizzonte finito i picchi sono transitori di 30–60 minuti, il banco pieno li assorbe, e il $P(\text{OOS})$ complessivo resterà sotto il 5% (attività 6–8).

Il profilo risultante,

$$\text{casce} = [2, 3, 3, 4, 4, 3, 3, 3, 3, 4, 4, 4],$$

$$\text{mag} = [1, 1, 1, 2, 2, 1, 1, 1, 2, 2, 2, 2],$$

vale 40 ore-cassa e 18 ore-magazzino al giorno, cioè un costo del personale di

$$40 \cdot 26 + 18 \cdot 18 = \mathbf{1\,364\ \text{€/giorno}}$$

contro i 1 992 della gestione attuale (–31,5% sul personale).




Figura 10: Scomposizione del costo totale (lavoro / inventario / attesa) per ogni combinazione di staffing, fascia per fascia: a sinistra di ogni gruppo lo staffing minimo (domina il costo di attesa e shortage), a destra quello pieno (domina il lavoro); * = configurazione scelta, bordo rosso = vincolo OOS violato, tratteggio = instabile. Nelle fasce di punta tutte le barre stabili sono bordate di rosso: l'evidenza visiva che il collo è la catena di rifornimento, non lo staffing.




Figura 11: Verifica a fronte di Pareto costo-tempo di risposta delle 96 configurazioni: le scelte (stelle) giacciono sul ginocchio del fronte della propria fascia.

Dal profilo ottimo ai turni realistici (preparazione dell'attività 7)

Il profilo di staffing per fascia non è direttamente attuabile: preso alla lettera implicherebbe contratti da una o due ore. In coda all'attività 5 il profilo viene quindi tradotto in **turni contigui realistici** con tre regole: decomposizione del profilo in turni (chi apre per il picco chiude a fine picco), durata minima di 3 ore — i turni-spike sono estesi verso le ore adiacenti a domanda più alta, producendo solo sovra-copertura — e durata massima di 8 ore, oltre la quale il turno è spezzato su due persone. Per costruzione la copertura oraria risultante è *sempre maggiore o uguale* allo staffing ottimo.

Il risultato è un organico di **8 cassieri e 4 magazzinieri** con turni tra le 3 e le 8 ore (figura), per una copertura di 41 ore-cassa e 19 ore-magazziniere: il **costo del realismo** — la sovra-copertura necessaria a rendere i turni contrattualmente sensati — è di sole 1 + 1 ore, cioè +44 €/giorno (1 408 €/giorno di personale). Le due versioni dello staffing — profilo ottimo puro e turni realistici — diventano gli scenari delle attività 6 e 7, dove sono rivalutate per intero sulla giornata reale.




Figura 12: Turnazione realistica generata dal profilo ottimo: diagramma dei turni (in alto) e copertura oraria risultante contro staffing ottimo e domanda $\lambda(t)$ (in basso). La copertura non scende mai sotto il profilo ottimo.

10.3 Attività 6 — Scenario ottimizzato sulla giornata reale

Attività 6 — orizzonte: finito (128 repliche)	
Domanda	le due scelte della fase — inventario (attività 4, deciso sul finito) e staffing (attività 5, deciso sull'infinito) — reggono <i>insieme</i> la giornata operativa completa, vincoli compresi?
Esito	sì: 2 104 €/giorno (−22,8% sulla baseline), $P(\text{OOS}) = 3,94\% \leq 5\%$ sull'intera giornata, $\mathbb{E}[T] = 393 \text{ s}$ (+56 s).

Lo scenario **Ottimizzato** ricompone le decisioni della fase: staffing a profilo $[2, 3, 3, 4, 4, 3, 3, 3, 3, 4, 4, 4]$ casse e $[1, 1, 1, 2, 2, 1, 1, 1, 2, 2, 2, 2]$ magazzinieri, inventario $s = \{75, 65, 55, 40, 30\}$ con $R = 30$ minuti. La valutazione usa la stessa identica metodologia della baseline (128 repliche, profilo NSPP, banco pieno, stessi stream): questo passaggio *chiude il cerchio* tra i due orizzonti — le decisioni prese a λ costante devono dimostrarsi valide nella giornata non stazionaria, l'unico contesto in cui i vincoli hanno significato operativo.

I risultati confermano le scelte. Il costo scende a 2 104 €/giorno (1 364 di personale + 740 d'inventario, −22,8% sul totale baseline). Il punto metodologicamente notevole è il vincolo di

servizio: $P(\text{OOS}) = 3,94\%$, **rispettato sull'intera giornata** — nonostante nelle cinque fasce di punta l'attività 5 non avesse trovato alcuna configurazione ammissibile sotto stress perpetuo. È la conferma quantitativa della divisione dei compiti tra orizzonti dichiarata nel piano: lo stress test a λ costante serviva a *scegliere* la configurazione stabile di costo minimo, non a prevedere il servizio di giornata; nella giornata reale i picchi durano 30–60 minuti, il banco pieno li attraversa, e le perdite restano entro il vincolo (figura). Il tempo di risposta sale a $\mathbb{E}[T] = 392,5 \text{ s}$ (+56 s sulla baseline): è il prezzo, atteso, del passaggio delle casse da sovradimensionate a dimensionate. Tutta la domanda resta servita (810 clienti/giorno) e il delivery lag medio (23 minuti) resta entro il periodo di revisione.




Figura 13: Scenario ottimizzato: livelli di scorta delle cinque classi lungo la giornata (medie su 128 repliche). Il profilo a dente di sega segue i cicli revisione-carico da 30 minuti; i minimi più profondi cadono nelle fasce di punta ma non collasano a zero: la politica scelta nell'attività 4 assorbe i picchi che nello stress test dell'attività 5 risultavano insostenibili.

10.4 Attività 7 — Scenario con turnazione realistica

Attività 7 — orizzonte: finito (128 repliche)	
Domanda	quanto costa, in termini di prestazioni ed economici, rendere lo staffing ottimo attuabile con turni contrattuali contigui (3–8 ore)?
Esito	quasi nulla: 2 116 €/giorno (−22,4%, solo +12 € rispetto all’ottimo puro), $P(\text{OOS}) = 3,71\%$ — il migliore dei tre scenari — $\mathbb{E}[T] = 392$ s.

Lo scenario **Ottimizzato + turni** sostituisce al profilo ottimo la copertura oraria dei turni generati in coda all’attività 5 (8 cassieri e 4 magazzinieri, turni da 3 a 8 ore, copertura mai inferiore al profilo). Tutto il resto — inventario, metodologia, stream — è identico all’attività 6, così la differenza misura esattamente il costo del realismo contrattuale.

Il personale sale a 1 408 €/giorno (+44), ma il costo d’inventario *scende* a 708 € (−32): le due ore di sovra-copertura non cadono a caso — l’algoritmo

dei turni le colloca nelle fasce adiacenti ai picchi — e la cassa e il magazziniere in più proprio a ridosso delle ore critiche riducono lo shortage. Il risultato netto è un costo totale di 2 116 **€/giorno**, appena +12 € (+0,5%) rispetto all’ottimo teorico, con il **miglior $P(\text{OOS})$ dei tre scenari (3,71%)** e un tempo di risposta indistinguibile da quello dell’attività 6 (392,2 s contro 392,5). Il vincolo contrattuale, in altre parole, non erode il beneficio dell’ottimizzazione: parte del suo costo si ripaga da solo in minori perdite.

10.5 Attività 8 — Confronto finale dei tre scenari

Attività 8 — orizzonte: finito (analisi comparativa delle attività 3, 6 e 7)	
Domanda	quanto si risparmia rispetto alla gestione attuale, e a quale prezzo sulle prestazioni percepite dal cliente?
Esito	−22,4% di costo giornaliero nello scenario raccomandato (turni realistici), vincolo out-of-stock rispettato con margine, +56 s di tempo di risposta end-to-end.

Il confronto finale affianca i tre scenari valutati nelle attività 3, 6 e 7 — tutti sulla stessa giornata a orizzonte finito, con le stesse 128 repliche e gli stessi stream (common random numbers), quindi direttamente confrontabili riga per riga. La tabel-

la riassume i numeri già discussi nelle rispettive attività; qui si aggiungono il confronto *per finestra* lungo la giornata (figure) e la lettura economica complessiva.

Scenario	Personale (€/gg)	Inventario (€/gg)	Totale (€/gg)	Δ costo	$P(\text{OOS})$	$\mathbb{E}[T]$ (s)
Baseline	1 992	734	2 726	—	4,14%	336
Ottimizzato	1 364	740	2 104	−22,8%	3,94%	393
Ottimizzato + turni	1 408	708	2 116	−22,4%	3,71%	392

Tabella 6: Confronto economico e di servizio dei tre scenari sulla giornata operativa (medie su 128 repliche; delivery lag medio 24/23/23 minuti rispettivamente). Il vincolo $P(\text{OOS}) \leq 5\%$ è rispettato in tutti gli scenari.

Lettura economica

Il costo giornaliero scende da 2 726 a 2 104 € (−22,8%, circa −620 €/giorno): su un anno di circa 305 giorni operativi il risparmio è dell'ordine di **190 000 €**. La quasi totalità del risparmio viene dal personale (−628 €/giorno), in accordo con l'impostazione dello studio: l'inventario — guardrail, non leva — contribuisce marginalmente, e infatti il suo costo resta pressoché invariato tra gli scenari (708–740 €/giorno).

La versione con i **turni realistici** costa solo 12 €/giorno più dell'ottimo puro (+0,5%): la sovracopertura imposta dai vincoli contrattuali (turni di almeno 3 ore) non erode il risparmio, e anzi la sua ora-cassa aggiuntiva nelle fasce di transizione produce il $P(\text{OOS})$ migliore dei tre scenari (3,71%). È lo scenario raccomandato: direttamente attuabile e economicamente indistinguibile dall'ottimo teorico.

Lettura del servizio

Entrambi gli scenari ottimizzati rispettano il vincolo sull'out-of-stock, con un margine perfino migliore della baseline (3,7–3,9% contro 4,14%): il taglio del personale non peggiora le perdite perché

la loro causa — come mostrato dal flusso forzato e dalla ricerca di staffing — è la capacità della catena di rifornimento nei picchi, non il numero di casse, e su quella agisce l'inventario ottimizzato (soglie più alte sulle classi critiche).

Il prezzo pagato è sul **tempo di risposta**: da 336 a 392 secondi end-to-end (+56 s, +17%), cioè da 5,6 a 6,5 minuti per l'intero percorso cassa–robot–pagamento. L'aumento è l'effetto atteso e voluto del passaggio delle casse da sovradimensionate ($\rho \approx 0,3$ –0,6 in baseline) a dimensionate ($\rho \approx 0,6$ –0,9), è distribuito lungo la giornata senza esplosioni nelle fasce di punta (figura), e rientra nel guardrail qualitativo fissato negli obiettivi: un minuto in più di permanenza a fronte di un quinto dei costi è il termine di scambio che lo studio quantifica e consegna alla decisione del gestore.

Cosa non cambia

Le utilizzazioni dei bracci robotici e del percorso di rifornimento sono sostanzialmente invariate tra gli scenari: lo staffing non tocca il robot (capacità fissa) e il throughput è conservato — tutta la domanda viene servita in ogni scenario (810 clienti/giorno, abbandoni disattivati). Questo con-

ferma che l’ottimizzazione ha agito solo sulle leve cuore automatizzato del sistema.
dichiarate, senza effetti collaterali nascosti sul




Figura 14: Quadro economico e di servizio dei tre scenari: costo giornaliero scomposto (personale + inventario) con variazione rispetto alla baseline, $P(OOS)$ contro la soglia SLA del 5%, e tempo di risposta medio di sistema.




Figura 15: Tempo di risposta di sistema lungo la giornata (medie per finestra su 128 repliche): gli scenari ottimizzati (blu, arancio) pagano un aumento contenuto e distribuito rispetto alla baseline (grigio), senza degenerazioni nelle fasce di punta.




Figura 16: Utilizzazione delle casse lungo la giornata: il profilo ottimizzato porta le casse dalla zona di sovradimensionamento della baseline a una zona di lavoro efficiente, seguendo la domanda fascia per fascia.




Figura 17: Utilizzazione del Braccio Due lungo la giornata: pressoché identica nei tre scenari — l'ottimizzazione dello staffing non altera il carico sul robot, il cui throughput è conservato.

11 Conclusioni

Lo studio ha modellato una farmacia con dispensazione robotizzata Gollmann come rete di code con inventario integrato, l'ha verificata e validata, e ne ha ottimizzato la gestione operativa a parità di architettura. L'obiettivo dichiarato — ridurre i costi di esercizio senza degradare il servizio — è quantificato dal risultato finale: **-22,4% di costo giornaliero** ($\approx 190\,000\text{ €/anno}$) nello scenario attuabile con turni realistici, con il vincolo sull'out-of-stock rispettato ($3,71\% \leq 5\%$) e un aumento contenuto del tempo di risposta (+17%, circa un minuto sul percorso end-to-end).

Il percorso metodologico ha seguito l'ordine prescritto: modello concettuale e delle specifiche, analisi operativa del flusso forzato, verifica (bilanci esatti, leggi di Little, accordo con $M/M/1$, $M/M/2$ e Pollaczek–Khinchine entro gli intervalli di confidenza, test degenerato dell'inventario con match esatto sul riferimento del corso), validazione (plausibilità, check di flusso, sensitività alle assunzioni distributive), quindi il **piano sperimentale in otto attività su due fasi** — prima il sistema attuale (transitorio, calibrazione dei batch, baseline), poi l'ottimizzazione (inventario, staffing, scenari ottimizzati, confronto) — con l'orizzonte di simulazione dichiarato e motivato attività per attività: **finito** (128 repliche della giornata NSPP) per baseline, ricerca d'inventario e scenari; **infinito** (batch means 64×1024 , Chatfield superato con $b = 1024$, warm-up 10 000 job) per la stima del warm-up, la calibrazione e il ranking dello staffing a parità di domanda.

Alcune **scelte di simulazione** si sono rivelate strutturanti e meritano di essere richiamate con il loro esito. “Un ordine = un job” ha eliminato il fork-join e reso veritiere le utilizzazioni; il routing probabilistico fisso con finestra protetta ha reso la rete analizzabile per centro (le quote effettive 0,133/0,867 sono confermate dalle utilizzazioni misurate); la priorità ai prelievi sul Braccio Uno ha allineato i tempi dei clienti sui due brac-

ci; la politica lost-sales ha ancorato la metrica di servizio al comportamento reale del cliente di farmacia; la disattivazione degli abbandoni ha isolato il sottosistema d'inventario dandogli una domanda ben definita; il cap dei picchi a 0,0255 req/s ha mantenuto il collo di bottiglia dei clienti (Braccio Due) entro $\rho = 0,95$.

Il risultato concettualmente più interessante riguarda il **ruolo dell'inventario**: l'asimmetria dei costi ($\approx 500\times$ tra shortage e giacenza) lo rende un guardrail, non una leva di risparmio, e l'analisi del flusso forzato mostra che sotto domanda di picco sostenuta il primo limite del sistema è la **catena di rifornimento** ($X_{\max} \approx 0,023\text{ req/s}$), non le casse: nessuno staffing può comprare livelli di servizio che il carico del robot non riesce a sostenere. Nella giornata reale i picchi sono transitori e il banco li assorbe — ma è questo vincolo, non il costo del personale, a porre il pavimento sotto il quale lo staffing non può scendere.

Limiti e sviluppi futuri

Tre estensioni naturali restano fuori dallo scope. (i) *De-burst delle revisioni*: scaglionare le revisioni delle cinque classi con offset temporali romperebbe i burst di riordino che oggi producono le code al carico e i lag oltre R , accorciando il lead time nei picchi a throughput invariato. (ii) *Disciplina del carico stato-dipendente*: servire i carichi in ordine di urgenza di scorta (prima la classe più vicina allo stockout) anziché FIFO ridurrebbe gli out-of-stock “di tempismo” a costo zero, essendo il lavoro totale conservato; da valutare per confronto simulativo a parità di stream. (iii) *Riattivazione degli abbandoni*: reintrodurre il renegeing permetterebbe di studiare l'interazione tra pazienza dei clienti e staffing ridotto, completando il quadro del trade-off servizio-costo. Sul piano strumentale, la misura del delivery lag andrebbe raffinata da per-ordine a per-confezione, coerente con il carico incrementale.

Riferimenti bibliografici

- [1] L. M. Leemis, S. K. Park, *Discrete-Event Simulation: A First Course*, Pearson Prentice Hall, 2006.
- [2] S. K. Park, K. W. Miller, “Random Number Generators: Good Ones Are Hard to Find”, *Communications of the ACM*, vol. 31, no. 10, pp. 1192–1201, 1988.
- [3] J. D. C. Little, “A Proof for the Queuing Formula: $L = \lambda W$ ”, *Operations Research*, vol. 9, no. 3, pp. 383–387, 1961.

- [4] J. F. C. Kingman, “*The Single Server Queue in Heavy Traffic*”, Mathematical Proceedings of the Cambridge Philosophical Society, vol. 57, no. 4, pp. 902–904, 1961.
- [5] C. Chatfield, *The Analysis of Time Series: An Introduction*, 6th ed., Chapman & Hall/CRC, 2003.
- [6] M. Harchol-Balter, *Performance Modeling and Design of Computer Systems: Queueing Theory in Action*, Cambridge University Press, 2013.
- [7] S. Kurkowski, T. Camp, M. Colagrosso, “*MANET Simulation Studies: The Incredibles*”, ACM SIGMOBILE Mobile Computing and Communications Review, vol. 9, no. 4, pp. 50–61, 2005.
- [8] V. de Nitto Personè, *Dispense del corso di Performance Modeling of Computer Systems and Networks*, Università degli Studi di Roma Tor Vergata, a.a. 2025/2026.